UNIVERSIDAD POLITÉCNICA DE MADRID

ESCUELA TÉCNICA SUPERIOR
DE INGENIEROS DE TELECOMUNICACIÓN



GRADO EN INGENIERÍA BIOMÉDICA

TRABAJO FIN DE GRADO

IMPLEMENTACIÓN DE ALGORITMOS PARA LA SEGMENTACIÓN DE REGIONES CON LINFOCITOS INFILTRANTES TUMORALES EN IMÁGENES HISTOPATOLÓGICAS DE CÁNCER DE MAMA MEDIANTE TÉCNICAS DE APRENDIZAJE PROFUNDO

PABLO PÉREZ GÓMEZ

2025

GRADO EN INGENIERÍA BIOMÉDICA

TRABAJO DE FIN DE GRADO

Título: IMPLEMENTACIÓN DE ALGORITMOS PARA LA SEGMENTACIÓN DE REGIONES CON LINFOCITOS INFILTRANTES TUMORALES EN IMÁGENES HISTOPATOLÓGICAS DE CÁNCER DE MAMA MEDIANTE TÉCNICAS DE APRENDIZAJE PROFUNDO

Autor: Pablo Pérez Gómez

Tutor: Juan Martínez-Aedo Castro

Cotutor: Irene Carretero Barrio

Ponente: María Jesús Ledesma Carbayo

Departamento: Departamento de ingeniería electrónica (grupo BIT)

MIEMBROS DEL TRIBUNAL

Presidente: D. ……

Vocal: D. ……..

Secretario: D. ……..

Suplente: D. ……..

Los miembros del tribunal arriba nombrados acuerdan otorgar la calificación de:

Madrid, a de de 20…

UNIVERSIDAD POLITÉCNICA DE MADRID

ESCUELA TÉCNICA SUPERIOR
DE INGENIEROS DE TELECOMUNICACIÓN



GRADO EN INGENIERÍA BIOMÉDICA

TRABAJO FIN DE GRADO

IMPLEMENTACIÓN DE ALGORITMOS PARA LA SEGMENTACIÓN DE REGIONES CON LINFOCITOS INFILTRANTES TUMORALES EN IMÁGENES HISTOPATOLÓGICAS DE CÁNCER DE MAMA MEDIANTE TÉCNICAS DE APRENDIZAJE PROFUNDO

PABLO PÉREZ GÓMEZ

2025

RESUMEN

El cáncer de mama es una de las principales causas de mortalidad en mujeres a nivel mundial. Entre los biomarcadores más relevantes para su pronóstico destacan los linfocitos infiltrantes tumorales (TILs), cuya presencia se asocia con una mejor respuesta al tratamiento y menor riesgo de recurrencia.

Este Trabajo Fin de Grado tiene como objetivo desarrollar un sistema basado en aprendizaje profundo para la segmentación automática de regiones ricas en TILs en imágenes histopatológicas teñidas con hematoxilina y eosina (H&E). Para ello, se emplearon arquitecturas de **aprendizaje profundo** como nnU-Net y el modelo CellViT, aplicados sobre bases de datos públicas y una cohorte externa real del Hospital Ramón y Cajal.

En primer lugar, se utilizaron dichas bases de datos públicas con anotaciones de TILs y se entrenaron modelos de segmentación basados en nnU-Net. Posteriormente, se incorporó el modelo CellViT para generar nuevas segmentaciones automáticas, que se emplearon en un segundo entrenamiento con el objetivo de mejorar el rendimiento del modelo inicial. Los resultados obtenidos tanto en la base de datos pública como en la cohorte externa evidencian una mejora notable en la calidad de las segmentaciones al combinar ambos enfoques (DICE: 0,6 vs 0,8), lo que refuerza el potencial de esta estrategia en el análisis automático de imágenes histopatológicas.

El proyecto ha demostrado que la combinación de modelos de **segmentación de áreas como nnU-Net y de segmentación de células como CellViT++** permite identificar de forma más precisa las regiones con TILs en imágenes histopatológicas, generando modelos más consistentes. Esta mejora puede facilitar el trabajo del patólogo y contribuir a decisiones terapéuticas más personalizadas, alineadas con los principios de la medicina de precisión.

PALABRAS CLAVE

Linfocitos infiltrantes tumorales (TILs), cáncer de mama, imágenes histopatológicas, aprendizaje profundo, nnU-Net, CellViT, segmentación, medicina de precisión, MammaPrint, patología digital.

ABSTRACT

Breast cancer is one of the leading causes of mortality among women worldwide. Among the most relevant prognostic biomarkers are tumor-infiltrating lymphocytes (TILs), whose presence is associated with a better response to treatment and a lower risk of recurrence.

This Bachelor's Thesis aims to develop a deep learning-based system for the automatic segmentation of TIL-rich regions in hematoxylin and eosin (H&E)-stained histopathological images. To this end, **Deep Learning** architectures such as nnU-Net and the CellViT model were employed, applied to public datasets and an external real-world cohort from Hospital Ramón y Cajal.

First, publicly available datasets with TIL annotations were used to train segmentation models based on nnU-Net. Subsequently, the CellViT model was incorporated to generate new automatic segmentations, which were employed in a second training phase to improve the performance of the initial model. The results obtained on both the public dataset and the external cohort show a significant improvement in segmentation quality when combining both approaches (DICE: 0.6 vs 0.8), highlighting the potential of this strategy for the automatic analysis of histopathological images.

The project has demonstrated that combining **area segmentation models such as nnU-Net with cell segmentation models like CellViT++** enables more accurate identification of TIL-rich regions in histopathological images, leading to more consistent models. This improvement can support pathologists in their work and contribute to more personalized therapeutic decisions, in line with the principles of precision medicine.

KEYWORDS

Tumor-infiltrating lymphocytes (TILs), breast cancer, histopathological images, deep learning, nnU-Net, CellViT, segmentation, precision medicine, MammaPrint, digital pathology.

ÍNDICE

1. Introducción ..... **¡Error! Marcador no definido.**
1.1. Contexto y relevancia del cáncer de mama 1
1.2. Importancia de los TILs en el cáncer de mama y técnicas de cuantificación 1
2. OBJETIVOS 3
3. CONTEXTO 5
3.1. Contexto clínico 5
3.1.1. Cáncer de mama: epidemiología y relevancia clínica 5
3.1.2. Pronóstico del cáncer de mama y test 5
3.1.3. Definición y función de los TILs 6
3.1.4. Valor pronóstico y predictivo de los TILs 7
3.1.5. Relevancia según el subtipo tumoral 7
3.2. Contexto técnico 8
3.2.1. Limitaciones de la evaluación manual de los TILs 8
3.2.2. Automatización e inteligencia artificial para la evaluación de TILs 8
3.2.3. Modelos de segmentación y pipeline empleado 9
3.2.4. Limitaciones actuales y desafíos 16
3.2.5. Relación entre TILs y Evaluación del Riesgo con MammaPrint 16
4. MATERIALES Y METODOLOGÍA 18
4.1. Recursos y entorno de trabajo 18
4.1.1. Hardware utilizado 18
4.1.2. Software y librerías 18
4.2. Bases de datos empleadas 19
4.2.1. CrowdsourcingDataset-Amgadetal2019 19
4.2.2. BCSS-WSSS 20
4.3. Desarrollo del proyecto 22
4.4. Preprocesamiento y preparación de datos 23
4.4.1. Conversión de anotaciones a máscaras 23
4.4.2. Organización de carpetas 23
4.4.3. Renombrado 25
4.5. Entrenamiento de los modelos con las máscaras originales 25
4.5.1. Entrenamiento de la nnU-Net 25

4.5.2. Evaluación del modelo 28
4.6. Segmentación con CellViT 29
4.6.1. Ejecución de CellViT sobre una base de datos 29
4.7. Generación de máscaras a partir de las segmentaciones de CellViT 30
4.8. Entrenamiento del modelo con las máscaras generadas con CellViT 33
4.8.1. Reentrenamiento de la red nnU-Net con las máscaras de CellViT 33
4.8.2. Evaluación del modelo 33
4.9. Inferencia con cohorte externa 33
5. RESULTADOS 35
5.1. Experimento 1 - Resultados del modelo con las anotaciones originales 35
5.1.1. Entrenamiento y validación con la base de datos *CrowdsourcingDataset* 35
5.1.2. Entrenamiento y evaluación con la base de datos *BCSS-WSSS* 37
5.1.3. Comparación de resultados entre ambas bases de datos 39
5.2. Experimento 2 - Resultados del modelo combinado con CellViT 40
5.2.1. Resultados de segmentación de TILs con CellViT sobre la base de datos CrowdsourcingDataset 40
5.2.2. Reentrenamiento de la nnU-Net con las nuevas máscaras 43
5.2.3. Evaluación del modelo combinado 43
5.2.4. Comparación frente al modelo base 44
5.3. Evaluación final sobre cohorte externa (MammaPrint) 45
6. Conclusiones y perspectivas futuras 48
7. BIBLIOGRAFÍA 50
8. Anexo 56
8.1. Anexo 1: paquetes instalados en cada uno de los entornos 56
8.1.1. Entorno nnU-Net v2 56
8.1.2. Entorno CellViT 57
8.1.3. Otros entornos 57
8.2. Anexo 2: impactos económicos, éticos, sociales y medioambientales. 58
8.2.1. Impactos económicos 58
8.2.2. Impactos éticos y sociales 59
8.2.3. Impactos medioambientales 60
8.2.4. Conclusiones 60
8.3. Anexo 3: presupuesto económico 61

ÍNDICE DE FIGURAS

Figura 1. Incidencia del cáncer de mama en mujeres, por países, para el año 2020, según los datos de GLOBOSCAN 2020 [10]. 5
Figura 2. Arquitectura U-Net estándar utilizada como base en nnU-Net [26]....11
Figura 3. procesado de nnU-Net [23]. 12
Figura 4. Arquitectura de CellViT para segmentación celular precisa [30]. 14
Figura 5. estructura de carpetas de la base de datos CrowdsourcingDataset-Amgad [54]. 19
Figura 6. Interfaz de HistomicsTK (obtenida de Amgad et al. en 2019) mostrando anotaciones multiclase sobre una lámina TCGA [7]. 20
Figura 7. ejemplo de parche de BCSS-WSSS, acompañado de su máscara asociada, en color azul zonas de TILs y en verde la clase estroma. 21
Figura 8. código de colores para la segmentación de BCSS-WSSS, tumor en rojo, estroma en verde, TIL en azul, necrosis en violeta, regiones excluidas o fondo en blanco. 21
Figura 9. Estructura de carpetas del dataset BCSS-WSSS, organizada en particiones de entrenamiento, validación y prueba, cada una con imágenes y máscaras asociadas. [53] 22
Figura 10. Planificación del flujo de trabajo del proyecto 22
Figura 11. Organización de la carpeta raw nnU-Net 24
Figura 12. Esquema que deben seguir las carpetas para usar la nnU-Net 25
Figura 13. Ejemplo de segmentación de CellViT en una imagen de CrowdsourcingDataset, desde QuPath. 30
Figura 14. Distribución espacial de los TILs (Inflammatory) detectados por CellViT en una muestra histológica. Cada punto representa el centroide de una célula clasificada como linfocito infiltrante.31
Figura 15. Máscara binaria generada a partir de la distribución de TILs, tras aplicar umbralización y operaciones morfológicas (dilatación-erosión). 32
Figura 16. Ejemplo de ROI de 2048x2048 píxeles extraída de WSI MammaPrint 34
Figura 17. Evolución del entrenamiento de nnU-Net de CrowdsourcingDataset. La línea azul muestra la función de pérdida en entrenamiento, la roja en validación interna, la verde punteada el coeficiente Dice por época y la verde continua su media móvil, reflejando una mejora progresiva..36
Figura 18.. Evolución del entrenamiento de nnU-Net de BCSS-WSSS. La línea azul indica la función de pérdida en entrenamiento, la roja en validación interna, la verde punteada el coeficiente Dice por época y la verde continua su media móvil, mostrando una rápida y sostenida mejora en la segmentación. 38
Figura 19. Representación Boxplot de los resultados DICE y desviación por cada caso, para ambos modelos Crowdsourging y BCSS-WSSS. 40
Figura 20. Imagen segmentada con CellViT. Las células en verde corresponden a las inflamatorias (TILs). 41
Figura 21. Mapa de distribución de TILs. 41
Figura 22. Comparación visual entre la segmentación de TILs realizada con CellViT (izquierda) y la máscara original de la base de datos (derecha). Se observa una mejora en la continuidad, cohesión y delimitación precisa de las regiones infiltradas. 42
Figura 23. Comparación visual entre la segmentación original (izquierda) y la generada mediante CellViT (derecha) sobre una misma imagen. 42

Figura 24. Evolución del entrenamiento de nnU-Net en el modelo de CrowdsourcingDataset combinado con CellViT. 43
Figura 25. Representación Boxplot de los resultados DICE y desviación por cada caso, para los dos modelos Crowdsourging con las máscaras originales y con CellViT.....44
Figura 26. Comparación visual de la predicción en el modelo con las máscaras originales (izquierda) y la generada mediante CellViT (derecha) sobre una misma imagen. 45
Figura 27. Comparación visual de la predicción en el modelo con las máscaras originales (izquierda) y la generada mediante CellViT (derecha) sobre una misma imagen. 46
Figura 28. Representación Boxplot de la inferencia sobre una cohorte externa de los dos modelos de Crowdsourcing con las máscaras originales y creadas por CellViT.....46

ÍNDICE DE TABLAS

Tabla 1. Estudios que han empleado nnU-Net 13
Tabla 2. Resumen de los experimentos realizados, modelos empleados, bases de datos utilizadas y tipo de validación aplicada.....35
Tabla 3. Resultados de los DICE para los cinco modelos 47

1. INTRODUCCIÓN

1.1. Contexto y relevancia del cáncer de mama

El cáncer de mama representa un importante problema de salud pública global, siendo el tumor más diagnosticado en mujeres. Se trata de una neoplasia que se origina en las células del tejido mamario y puede presentar diversos subtipos con características moleculares y clínicas distintas. Según datos de GLOBOCAN 2020, se estimaron más de 2,3 millones de nuevos casos y aproximadamente 670.000 muertes en ese mismo año. A pesar de los avances en cribado y tratamiento, la heterogeneidad biológica de este tipo de cáncer dificulta la estratificación del riesgo y la elección terapéutica óptima [1].

En los últimos años, la investigación en oncología de precisión ha prestado especial atención al estudio del microambiente tumoral, donde destaca el papel de los linfocitos infiltrantes de tumores (Tumor-Infiltrating Lymphocytes, TILs) como posible herramienta para mejorar el pronóstico y la personalización de terapias [2-3].

1.2. Importancia de los TILs en el cáncer de mama y técnicas de cuantificación

Los TILs son células del sistema inmunológico que se infiltran en el tejido tumoral y desempeñan un papel clave en la respuesta inmune contra el cáncer. Su presencia y densidad han sido ampliamente estudiadas como biomarcadores pronósticos y predictivos en diferentes subtipos de cáncer de mama, en particular en el cáncer de mama triple negativo (TNBC) y el cáncer de mama HER2 positivo. Evidencias científicas han demostrado que un mayor número de TILs se asocia con un mejor pronóstico y una mayor respuesta a tratamientos como la quimioterapia neoadyuvante e inmunoterapia. En este sentido, su evaluación se ha convertido en una herramienta potencialmente útil para guiar decisiones terapéuticas, reducir la toxicidad del tratamiento y mejorar la supervivencia de los pacientes [4-5].

Tradicionalmente, la localización y cuantificación de los TILs se ha realizado mediante evaluación visual de imágenes histopatológicas por parte de patólogos expertos, siguiendo criterios estandarizados. Sin embargo, este método presenta limitaciones significativas, como la variabilidad interobservador y la dificultad de implementación a gran escala. Para superar estas limitaciones, la inteligencia artificial (IA) y, en particular, las técnicas basadas en aprendizaje automático (Machine Learning, ML) y aprendizaje profundo (Deep Learning, DL), han surgido como herramientas innovadoras para la automatización y mejora de la localización, segmentación y cuantificación de los TILs en imágenes histológicas de cáncer de mama.

Modelos basados en redes neuronales convolucionales (CNNs) han demostrado una capacidad prometedora para la segmentación y análisis de TILs con alta precisión y reproducibilidad [6-7].

Paralelamente, en la oncología de precisión, el uso de firmas genéticas ha permitido una clasificación más refinada del riesgo y pronóstico en pacientes con cáncer de mama. Una de las herramientas más utilizadas es **MammaPrint**, una firma genética de 70 genes aprobada por la FDA que estratifica a los pacientes en dos categorías de riesgo de recurrencia: alto o bajo. La combinación de la evaluación de los TILs con MammaPrint podría mejorar la estratificación del riesgo y optimizar la selección de terapias en pacientes con cáncer de mama, permitiendo una mejor personalización del tratamiento. [8-9].

2. OBJETIVOS

El objetivo principal de este Trabajo Fin de Grado consiste en desarrollar y evaluar un sistema basado en DL que permita segmentar automáticamente regiones con TILs en imágenes histopatológicas teñidas con hematoxilina-eosina (H&E) de cáncer de mama, y proporcionar una segmentación que permita una cuantificación precisa y objetiva de los TILs, lo que en el futuro podría complementarse con firmas génicas como MammaPrint para mejorar la estratificación pronóstico-terapéutica en el contexto de la medicina de precisión.

Para alcanzar dicho objetivo, se plantean los siguientes subobjetivos específicos:

1. **Conocimiento del estado del arte mediante una revisión bibliográfica** detallada con el fin de analizar el estado actual del conocimiento sobre los TILs como biomarcadores pronósticos y predictivos en los distintos subtipos de cáncer de mama. Asimismo, se identificarán los avances más relevantes y las limitaciones que presentan tanto los métodos tradicionales de segmentación como las aproximaciones basadas en inteligencia artificial.

2. **Construcción y preparación del conjunto de datos** que se empleará para el entrenamiento y validación del modelo. Esta fase incluirá la recopilación y segmentación de bases de datos de imágenes histológicas de cáncer entejido mamario con anotaciones de regiones con TILs, así como la estandarización de parámetros clave como los formatos de imagen, la magnificación y los protocolos de preprocesado.

3. **Diseño y entrenamiento del modelo de segmentación**, centrándose en la configuración y optimización de la arquitectura nnU-Net para la detección precisa de TILs en cortes histológicos teñidos con H&E. Durante esta fase, se implementarán estrategias de validación cruzada y se ajustarán los principales hiperparámetros con el fin de maximizar el rendimiento del modelo.

4. **Evaluación** cuantitativa de los modelos desarrollados mediante métricas de desempeño como el coeficiente Dice, el índice de IoU, la precisión y la exhaustividad. Los resultados obtenidos se compararán con las evaluaciones realizadas por patólogos expertos, así como con otras soluciones basadas en algoritmos de segmentación previamente publicados en la literatura científica.

5. **Evaluar el uso del modelo CellViT como herramienta de segmentación complementaria** para mejorar las anotaciones originales de la base de datos, mediante la generación automatizada de regiones enriquecidas en TILs. Estas regiones se someterán a un proceso de dilatación y se utilizarán para reentrenar el modelo nnU-Net, con el objetivo de analizar el impacto de esta estrategia en el rendimiento del sistema de segmentación.

6. **Análisis crítico de las principales limitaciones** técnicas y clínicas detectadas durante el desarrollo del sistema, así como una **propuesta de mejoras** orientadas a incrementar la robustez, la interpretabilidad y la aplicabilidad clínica del modelo. Esta reflexión permitirá sentar las bases para futuras líneas de investigación en el ámbito de la segmentación automatizada de biomarcadores inmunológicos en cáncer de mama.

3. CONTEXTO

3.1. Contexto clínico

3.1.1. Cáncer de mama: epidemiología y relevancia clínica

En el ámbito clínico, el cáncer de mama continúa siendo uno de los principales desafíos en oncología, no solo por su elevada incidencia, con aproximadamente 2,3 millones de nuevos casos estimados en 2022 (Figura 1), sino también por su significativa mortalidad, con más de 670.000 fallecimientos atribuidos ese año. La heterogeneidad biológica que caracteriza a este tipo de neoplasia complica la clasificación de pacientes y la selección de tratamientos eficaces.

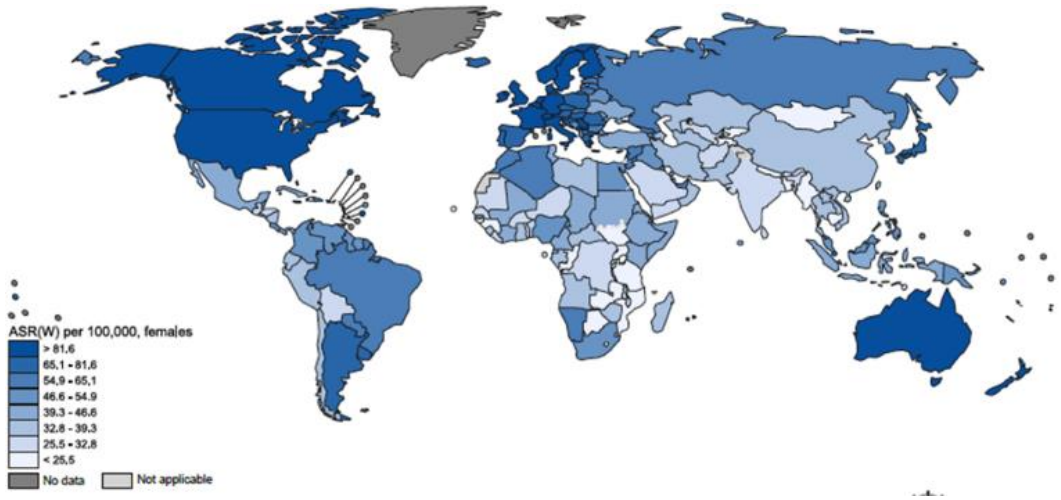


Figura 1. Incidencia del cáncer de mama en mujeres, por países, para el año 2020, según los datos de GLOBOSCAN 2020 [10].

3.1.2. Pronóstico del cáncer de mama y test

La correcta estratificación del riesgo de recurrencia en pacientes con cáncer de mama es esencial para la selección de tratamientos y poder evitar el uso de terapias innecesarias. En este contexto, herramientas como MammaPrint, un test genético basado en una firma génica de 70 genes, han sido aprobadas por la Food and Drug Administration (FDA) para clasificar a las pacientes en grupos de riesgo alto o bajo de recaída. A partir del perfil de expresión génica de la muestra tumoral, MammaPrint clasifica a los pacientes en alto o

bajo riesgo de recurrencia, lo que permite orientar la decisión sobre la necesidad de quimioterapia adyuvante. Este análisis es especialmente relevante en pacientes con tumores de receptores hormonales positivos (HR+) y HER2 negativos, donde la necesidad de tratamientos adicionales no siempre es clara [8-9].

El uso de MammaPrint ha demostrado ser una herramienta eficaz en la estratificación del riesgo y ha sido validado en ensayos clínicos multicéntricos. Sin embargo, existe la necesidad de mejorar su capacidad predictiva mediante la integración de otros biomarcadores que reflejen mejor la biología tumoral y la respuesta inmune del paciente.

Su uso ha demostrado ser útil en la toma de decisiones clínicas, especialmente en casos con riesgo clínico intermedio [9].

3.1.3. Definición y función de los TILs

En respuesta a esta complejidad, la oncología de precisión ha orientado sus esfuerzos hacia el estudio del microambiente tumoral. Dentro de este, la evaluación de TILs ha ganado protagonismo como posible herramienta para afinar el pronóstico, anticipar la respuesta inmunitaria y mejorar la personalización terapéutica, especialmente en subtipos como el cáncer de mama triple negativo y HER2 positivo [1,2,3,10].

Estas células inmunitarias, que incluyen linfocitos T, linfocitos B y células asesinas naturales (Natural Killers, NK), pueden modular la progresión tumoral mediante la producción de citoquinas y la activación de mecanismos de citotoxicidad contra células malignas [11].

Diversos estudios han resaltado la importancia de los TILs en la oncología, estableciendo su rol como biomarcadores inmunológicos con impacto pronóstico y predictivo. En particular, la cantidad y distribución de los TILs dentro del tumor y su estroma han sido correlacionadas con la respuesta al tratamiento y el pronóstico en distintos subtipos de cáncer de mama, como menciona Loi et al. (2014) [4]. Su evaluación se ha convertido en un criterio clave en la inmunooncología, al permitir una mejor comprensión del microambiente tumoral y su interacción con las terapias antitumorales.

3.1.4. Valor pronóstico y predictivo de los TILs

Los TILs han sido ampliamente estudiados como biomarcadores en cáncer de mama, particularmente en los subtipos triple negativo (TNBC) y HER2 positivo. La evidencia ha demostrado que un mayor número de TILs se asocia con una mejor respuesta a la quimioterapia neoadyuvante y una mayor tasa de supervivencia [12].

Varios estudios han explorado la relación entre la densidad de TILs y la eficacia de la quimioterapia en pacientes con cáncer de mama. En particular, Criscitiello et al. (2018) [13] propusieron una firma genética capaz de predecir la cantidad de TILs después de la quimioterapia neoadyuvante en pacientes con TNBC, sugiriendo que la respuesta inmune desempeña un papel clave en la eficacia del tratamiento. De nuevo, Denkert et al. (2015) [28] analizaron la presencia de TILs en pacientes con cáncer de mama tratados con quimioterapia neoadyuvante y encontraron que los tumores con mayor infiltración linfocitaria tienden a presentar perfiles genómicos asociados con un pronóstico más favorable. De manera similar, Herrero-Vicent et al. (2017) [14] y Pruneri et al. (2016) [29] demostraron que una mayor infiltración de linfocitos en pacientes con TNBC tratados con quimioterapia neoadyuvante se asocia con mejores tasas de respuesta patológica completa y una mejor supervivencia general.

3.1.5. Relevancia según el subtipo tumoral

El cáncer de mama triple negativo (TNBC) es un subtipo agresivo con opciones terapéuticas limitadas. Sin embargo, estudios como el de Adams et al. (2014) [15] han identificado que una alta densidad de TILs en TNBC está fuertemente asociada con un mejor pronóstico y una mayor supervivencia libre de enfermedad. Del mismo modo, en cáncer de mama HER2 positivo, la presencia elevada de TILs ha demostrado ser un factor predictivo positivo para la respuesta al tratamiento con trastuzumab y quimioterapia. Estos hallazgos han reforzado la importancia de la evaluación de TILs como un criterio adicional en la estratificación del riesgo y la personalización del tratamiento [16].

Aunque la mayoría de los estudios sobre TILs se han centrado en TNBC y HER2+, existe evidencia de su relevancia en otros subtipos de cáncer de mama. Kotoula et al. (2016) [17] realizaron un análisis agrupado de cuatro ensayos clínicos prospectivos y concluyeron que los tumores con alta densidad de TILs representan una entidad biológicamente favorable, independientemente del subtipo de cáncer de mama. Más

recientemente, Valenza et al. (2023) [18] analizaron la presencia de TILs en distintos subtipos y discutieron los desafíos en su evaluación como biomarcador, destacando la necesidad de mayor estandarización en su detección, cuantificación y reporte en la práctica clínica.

3.2. Contexto técnico

3.2.1. Limitaciones de la evaluación manual de los TILs

Históricamente, la evaluación de los TILs se ha basado en el análisis manual de imágenes histopatológicas por parte de patólogos expertos. Este proceso consiste en la observación de cortes tisulares teñidos con H&E y la cuantificación visual de la proporción de linfocitos infiltrantes en el estroma tumoral, siguiendo criterios estandarizados. Sin embargo, esta metodología manual adolece de ciertas limitaciones, como la dependencia del criterio del observador, la variabilidad entre evaluadores y un elevado grado de subjetividad en la cuantificación, incluso cuando se siguen pautas estandarizadas [19].

El principal desafío de este enfoque manual radica en la inconsistencia en la evaluación entre distintos observadores y centros médicos. Stanton et al. (2016) [20] realizaron una revisión sistemática sobre la variabilidad en la cuantificación de TILs y concluyeron que la falta de estandarización limita su implementación como biomarcador clínico. A pesar de los esfuerzos por definir guías estandarizadas, como las propuestas por el International Immuno-Oncology Biomarker Working Group, la necesidad de métodos más reproducibles y automatizados ha llevado al desarrollo de enfoques basados en inteligencia artificial para la segmentación y cuantificación de TILs.

3.2.2. Automatización e inteligencia artificial para la evaluación de TILs

La evaluación de los linfocitos infiltrantes de tumores ha evolucionado significativamente con el avance de las técnicas de inteligencia artificial. La aplicación de técnicas de aprendizaje automático y profundo en imágenes histopatológicas ha permitido automatizar y mejorar la detección y cuantificación de los TILs, superando las limitaciones de los métodos manuales. Estas técnicas han demostrado ser más eficientes, reproducibles y escalables, facilitando su integración en la práctica clínica. Modelos de DL han demostrado un rendimiento sobresaliente en la identificación y localización

precisa de TILs en imágenes Whole Slide Images (WSI), proporcionando análisis más objetivos y menos dependientes de la variabilidad interobservador.

Abousamra et al. (2022) [21] desarrollaron un modelo basado en DL para mapear la distribución de TILs en imágenes histológicas de 23 tipos de cáncer. Su estudio demostró la viabilidad de aplicar modelos entrenados en múltiples tipos de cáncer para la segmentación automática de TILs, con resultados comparables a los obtenidos por patólogos expertos. De manera similar, Zhang et al. (2023) [22] introdujeron SAMS-Net, una arquitectura de segmentación basada en mecanismos de atención y fusión de características multiescala, logrando una mejora en la precisión de detección de TILs.

Dentro de las técnicas actuales, la **nnU-Net** destaca especialmente por su capacidad adaptativa. Esta herramienta, concebida como una red universal para segmentación biomédica, se ajusta automáticamente a distintos conjuntos de datos mediante la selección dinámica de parámetros óptimos, diseño adaptativo de arquitecturas y estrategias avanzadas de preprocesamiento. Gracias a esta adaptabilidad, la nnU-Net permite obtener resultados robustos y reproducibles en una gran variedad de contextos biomédicos, incluidas las imágenes histológicas teñidas con H&E utilizadas para la detección de TILs. Su capacidad para reducir significativamente la variabilidad y subjetividad en la segmentación la convierte en una solución prometedora para su implementación en entornos clínicos reales [23].

Los enfoques basados en **ML han sido validados frente a los métodos tradicionales**, demostrando su superioridad en términos de eficiencia y reproducibilidad. Yosofvand et al. (2023) [24] compararon la detección automatizada de TILs con la evaluación manual en imágenes histopatológicas de cáncer de mama y encontraron una alta correlación entre los resultados obtenidos por el modelo de IA y los criterios de los patólogos. Además, Liu et al. (2024) [25] presentaron un enfoque basado en **segmentación panóptica**, combinando detección de instancias y segmentación semántica para mejorar la precisión y explicabilidad de la cuantificación de TILs, asegurando su aplicabilidad en entornos clínicos.

3.2.3. Modelos de segmentación y pipeline empleado

En este apartado se describe el flujo computacional completo que transforma WSIs histopatológicas H&E en máscaras binarias de TILs.

El flujo de trabajo abarca (i) preprocesado y normalización de los WSIs, (ii) entrenamiento de modelos de segmentación basados en DL, (iii) inferencia sobre conjuntos de prueba y (iv) post-procesado de las salidas para obtener métricas cuantitativas robustas. Se han seleccionado dos arquitecturas complementarias: nnU-Net y CellViT; por su capacidad de adaptación y su rendimiento contrastado en segmentación biomédica.

Existen otros modelos recientes como HookNet o SAMS-Net, diseñados para tareas similares de segmentación en histopatología. Sin embargo, en este trabajo se ha optado por una estrategia basada en nnU-Net y CellViT, dadas sus capacidades contrastadas y facilidad de integración en entornos prácticos [35,22].

3.2.3.1. Redes CNN autoconfigurables (nnU-Net)

Las **redes neuronales convolucionales** constituyen la piedra angular de la visión por computador moderna. Su funcionamiento se basa en la aplicación repetida de filtros aprendibles (*kernels*) que recorren la imagen y generan mapas de activación capaces de detectar patrones locales (bordes, texturas, formas). A diferencia de las redes neuronales tradicionales, al menos una de sus capas (la convolucional) utiliza operaciones de convolución en lugar de multiplicaciones de matrices densas, lo que permite explotar la estructura espacial de las imágenes de forma más eficiente. Al apilar sucesivas capas convolucionales y entremezclarlas con operaciones de reducción de resolución, la red construye representaciones jerárquicas: las primeras capas capturan detalles finos, mientras que las últimas recogen información semántica de alto nivel. Para tareas de segmentación biomédica (donde cada píxel necesita una propia etiqueta) las CNN se combinan con operaciones que recuperan gradualmente la resolución original y proporcionan un mapa denso de predicción [23].

En la segmentación de imágenes utilizando redes neuronales convolucionales, se aplicó la **estructura clásica U-Net**, que destaca por su sencillez y efectividad. Como se muestra en la Figura 2:

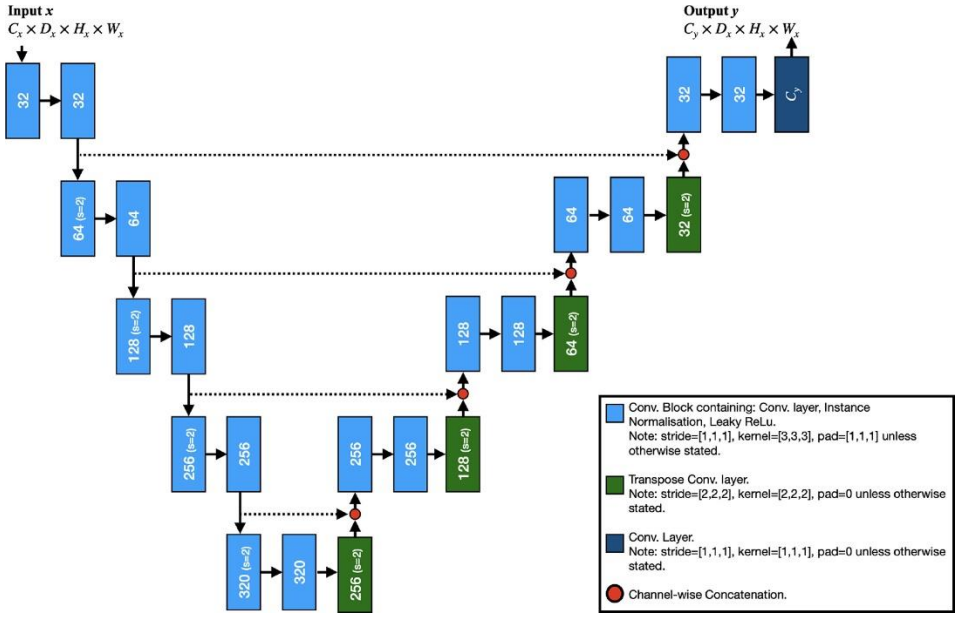


Figura 2. Arquitectura U-Net estándar utilizada como base en nnU-Net [26].

La arquitectura U-Net funciona como una red en forma de "U" que se divide en dos partes: una fase de contracción y otra de expansión. En la contracción o codificación (Figura 2 izquierda), la red aplica convoluciones y reducciones de resolución para extraer características importantes y captar el contexto general de la imagen. Luego, en la expansión o decodificación (Figura 2 derecha), recupera progresivamente la resolución original mediante operaciones de “upsampling” (aumento de resolución) y combinando la información previa con las características detalladas de las primeras capas, gracias a las llamadas “skip connections” (conexiones de salto). Esto permite que la red mantenga tanto el contexto global como el detalle local, lo cual es clave en tareas de segmentación, donde hay que clasificar cada píxel con precisión [38,62].

Aunque la U-Net estándar proporciona una plantilla robusta, su rendimiento real depende de elegir adecuadamente cientos de parámetros como son el tamaño de parche, la normalización, la tasa de aprendizaje (“learning rate”), la profundidad, etc. La red nnU-Net [23] automatiza ese proceso a través de un flujo de trabajo auto-configurable resumido en la Figura 3:

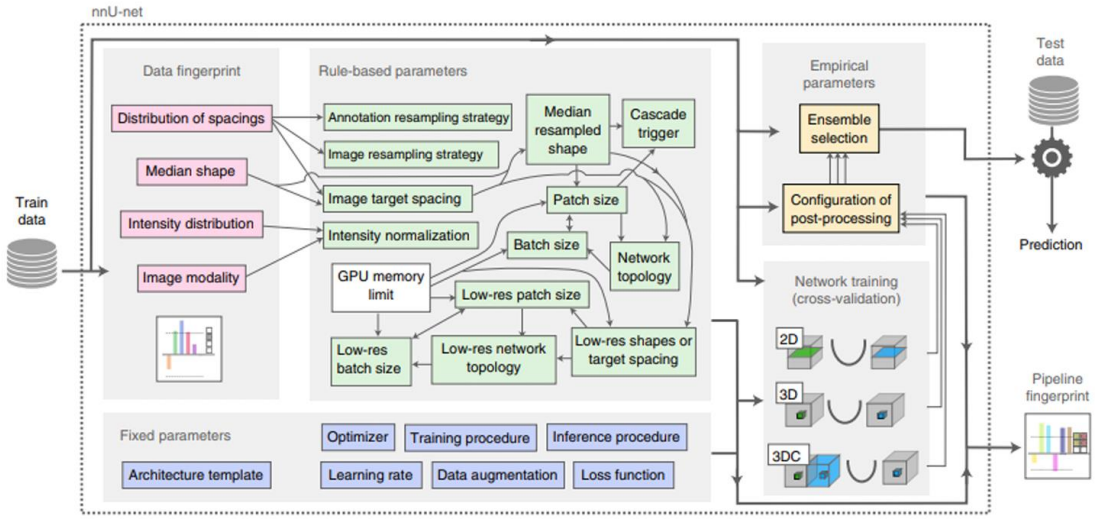


Figura 3. procesado de nnU-Net [23].

El procesado propio de la nnU-Net queda explicado en las siguientes fases:

- Huella de datos ("Data Fingerprint"): El sistema calcula estadísticas de la base de datos introducida: distribución de espaciados, forma mediana, histograma de intensidades y modalidad de imagen. Estos datos (bloques rosas en la figura 3) forman la "huella" que guía el resto de decisiones.
- Parámetros definidos por reglas ("Ruled-based parameters"): Reglas empíricas traducen la huella en parámetros concretos (bloques verdes en la figura 3): estrategia de re-muestreo, tamaño de parche, topología de la red o tamaño de batch respetando el límite de memoria GPU. Para imágenes H&E 2D (con las que se trabaja en este TFG), nnU-Net deshabilita la rama 3D y ajusta la red al modo 2D puro.
- Entrenamiento de red neuronal: Con la arquitectura seleccionada, el sistema ejecuta una validación cruzada k-fold y entrena las versiones 2D (e incluso 3D o 3D-cascaded si fuera pertinente). Los modelos resultantes se almacenan junto con su rendimiento (pipeline fingerprint).
- Parámetros empíricos: Una fase automática de búsqueda de post-procesado y selección de ensambles elige la combinación de modelos que maximiza la métrica objetivo (p. ej., Dice) en validación.
- Inferencia: El pipeline final se aplica a los datos de prueba para generar las máscaras de predicción.

Gracias a esta auto-configuración, nnU-Net elimina la búsqueda manual de hiperparámetros y entrega un modelo listo para su despliegue clínico, manteniendo la robustez y la reproducibilidad exigidas en entornos biomédicos.

En cuanto a **estudios realizados** que hayan empleado nnU-Net como herramienta base para la segmentación automática destacan:

- En el artículo original del modelo nnU-Net, Isensee et al. (2021) [23] evaluaron su rendimiento sobre el conjunto de datos Breast Tumor del Medical Segmentation Decathlon (Task05_Breast) [59]. El modelo logró un coeficiente Dice promedio de 0,89, demostrando su alta capacidad para segmentar tumores mamarios en imagen por resonancia magnética (IRM) con mínima intervención manual.
- Bermudez et al. (2023) [60], utilizaron la nnU-Net para segmentar lesiones mamarias en imágenes de resonancia magnética con contraste dinámico. Entrenaron el modelo en imágenes de escáneres de 3 Tesla, logrando un Dice de 0,86 ± 0,04 para la región tumoral, y mejorando la detección frente a U-Net tradicional y modelos FCN.
- Motaz Alqaoud et al. (2022) [61]: a partir de una segmentación de tejidos en MRI mamaria, emplearon la nnU-Net combinado con una segunda red para segmentar la mama, tejido fibroglandular y tumor en imágenes de resonancia magnética (T2W y STIR) de 10 pacientes. Obtuvieron un Dice de 0,95 para la mama, 0,83 para tejido graso y 0,41 para tumor.

En la Tabla 1 se presenta un resumen de los estudios sobre tejidos mammarios donde se aplicó la nnU-Net.

Tabla 1. Estudios que han empleado nnU-Net

Autor (año)	**Modalidad**	**Dice**
Isensee et al. (2021)	MRI(Task05_Breast,MSD)	0,89
Bermúdez et al. (2023)	DCE-MRI (3 Tesla)	0,86 ± 0,04
Alqaoud et al. (2022)	MRI (T2W, STIR)	0,95(mama);0,83(grasa);0,41 (tumor)

Además, existen múltiples estudios donde se aplicó nnU-Net para imágenes de lesiones como cáncer de pulmón [55, 56, 57], demostrando la eficacia de la segmentación empleando la nnU-Net en múltiples entornos clínicos.

3.2.3.2. Cell-ViT

CellViT es un modelo de segmentación de instancias desarrollado específicamente para imágenes histopatológicas a nivel celular. A diferencia de las arquitecturas clásicas basadas en U-Net, CellViT emplea una combinación de características convolucionales locales con transformadores visuales (ViT) (Figura 4) que permiten capturar relaciones espaciales de mayor alcance entre células, mejorando así la precisión en la segmentación de componentes celulares en entornos complejos como el microambiente tumoral [30].

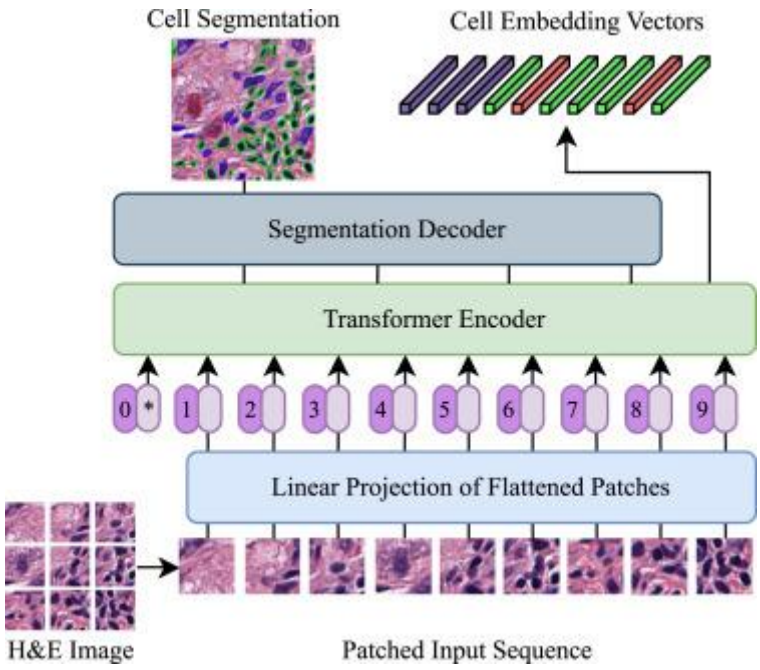


Figura 4. Arquitectura de CellViT para segmentación celular precisa [30].

La Figura 4 muestra el flujo de trabajo interno de CellViT, un modelo diseñado para segmentar células en imágenes histológicas H&E. El proceso comienza con la división de la imagen original en pequeños fragmentos o parches (Figura 4 abajo a la izquierda), que son aplanados y proyectados linealmente para formar una secuencia numérica que represente visualmente cada región. Esta secuencia alimenta al "Transformer Encoder", el componente responsable de entender las relaciones espaciales entre los distintos parches mediante mecanismos de autoatención.

Una vez procesada la secuencia por el codificador, las representaciones se transmiten al decodificador de segmentación (Segmentation Decoder), que reconstruye

un mapa detallado de cada célula presente en la imagen. Además, CellViT extrae vectores de características individuales por célula (Cell Embedding Vectors), que permiten clasificar tipos celulares o realizar tareas adicionales más allá de la segmentación. Finalmente, se genera una máscara de salida donde se visualiza la segmentación precisa de cada célula (Figura 4 arriba a la izquierda), diferenciada por color.

Posteriormente, se propuso CellViT++, una versión mejorada de CellViT que mantiene su arquitectura híbrida basada en transformadores, pero optimiza tanto la eficiencia computacional como la capacidad de generalización a distintos tejidos. CellViT++ introduce bloques de atención más ligeros y mecanismos de normalización más eficientes, permitiendo segmentar con precisión en imágenes de resolución gigapíxel con menor coste computacional. Además, ha sido diseñado como un modelo generalista, es decir, entrenado para funcionar correctamente en múltiples tareas de segmentación celular sin necesidad de ajustes específicos por tipo de tejido [30-31].

Cabe destacar que CellViT dispone de varios modelos preentrenados sobre grandes bases de datos de imágenes histopatológicas. Esta disponibilidad permite aplicar inferencias directamente utilizando los pesos ya entrenados, sin necesidad de realizar un nuevo proceso de entrenamiento desde cero, lo cual facilita su integración rápida en distintos flujos de trabajo [31].

En cuanto a aplicaciones destacadas del modelo CellViT, destacan Hörst et al. (2024) [31], donde CellViT fue entrenado y evaluado en el PanNuke [32], un conjunto de datos con aproximadamente 200.000 núcleos segmentados en 19 tipos de tejido. Logró un mean panoptic quality (mPQ) de alrededor 0,50 lo que indica una combinación equilibrada de buena segmentación (máscara) y alta precisión en la identificación de instancias. Además, consiguió un F1-detection de 0,83, demostrando que fue capaz de localizar las células casi con un 83 % de precisión y recuperación combinadas.

En el desafío clínico PUMA para melanoma, **combinar CellViT++ con nnU-Net** permitió alcanzar un Dice de 0,75 para segmentación de tejido, superando el baseline de 0,63; este modelo híbrido incluía detección de núcleos basada en CellViT++ [33-34].

En conjunto, los resultados obtenidos con CellViT y su versión mejorada CellViT++ confirman su eficacia para la segmentación celular en imágenes histopatológicas, gracias

a su arquitectura híbrida basada en transformadores y convoluciones. La combinación de CellViT++ con nnU-Net permitió abordar simultáneamente la detección de núcleos y la segmentación tisular, consolidándose como un enfoque robusto y escalable para el análisis automatizado de tejidos.

3.2.4. Limitaciones actuales y desafíos

A pesar del éxito de los enfoques de ML en la segmentación y cuantificación de TILs, existen desafíos significativos que limitan su adopción clínica.

3.2.4.1. Interpretabilidad y explicabilidad

Uno de los principales retos en la implementación de modelos de DL en histopatología es la falta de interpretabilidad de las predicciones. Liu et al. (2024) [25] enfatizaron la necesidad de desarrollar métodos que permitan explicar la segmentación y cuantificación de TILs de manera transparente para los patólogos y oncólogos. La implementación de enfoques basados en heatmaps, Grad-CAM y visualización de activaciones puede mejorar la confianza en estos modelos, pero aún se requiere una validación rigurosa en entornos clínicos.

3.2.4.2. Necesidad de bases de datos anotadas de alta calidad

Otro desafío clave es la disponibilidad de conjuntos de datos de entrenamiento bien anotados. Rauf et al. (2023) [27] destacaron que la mayoría de los modelos de ML dependen de imágenes histológicas con anotaciones precisas de TILs, lo que requiere un gran esfuerzo por parte de expertos en patología. La creación de bases de datos más amplias, junto con la implementación de estrategias de aumento de datos y aprendizaje por transferencia, podría mitigar este problema y mejorar la generalización de los modelos a diferentes tipos de tejido y condiciones de adquisición de imágenes.

3.2.5. Relación entre TILs y Evaluación del Riesgo con MammaPrint

La evaluación del riesgo de recurrencia en pacientes con cáncer de mama es un aspecto fundamental para la toma de decisiones terapéuticas. En este contexto, la combinación de biomarcadores inmunológicos, como los TILs, con herramientas de

estratificación genómica, como MammaPrint, ha surgido como una estrategia prometedora para mejorar la precisión del pronóstico y la personalización del tratamiento.

3.2.5.1. Potencial integración de ML para mejorar la evaluación del riesgo

La aplicación de técnicas de ML en el análisis conjunto de TILs y MammaPrint podría mejorar significativamente la predicción del riesgo de recurrencia en cáncer de mama. El desarrollo de modelos de aprendizaje automático que combinen datos histopatológicos con información de expresión génica permitiría:

- **Mejorar la precisión de la clasificación de riesgo** mediante la integración de datos de imagen y transcriptómica.
- **Personalizar la terapia** al identificar subgrupos de pacientes que podrían beneficiarse o no de tratamientos adyuvantes.
- **Optimizar la toma de decisiones clínicas**, reduciendo la incertidumbre en pacientes con perfiles genómicos intermedios.

El uso de modelos de DL para el análisis automatizado de TILs, junto con algoritmos de predicción basados en la expresión génica, podría proporcionar una herramienta más robusta y objetiva para la evaluación del riesgo. Estudios recientes han demostrado que la combinación de datos histológicos con firmas genéticas mejora la precisión de los modelos predictivos y podría reducir la necesidad de tratamientos agresivos en pacientes con baja probabilidad de recurrencia [37].

4. MATERIALES Y METODOLOGÍA

4.1. Recursos y entorno de trabajo

4.1.1. Hardware utilizado

El desarrollo del presente trabajo se llevó a cabo en un entorno de computación de alto rendimiento proporcionado por el servidor alojado en la infraestructura del departamento del grupo *Biomedical Image Technologies* (BIT) de la Universidad Politécnica de Madrid. Para la ejecución de tareas intensivas en cómputo, como la segmentación con modelos DL y el entrenamiento de redes neuronales convolucionales, se empleó una GPU NVIDIA A100 de 40 GB, altamente optimizada para operaciones tensoriales y paralelización masiva.

Además, el sistema contaba con 512 GB de memoria RAM y procesadores Intel Xeon Gold, lo que permitió una gestión eficiente de grandes volúmenes de imágenes histológicas en formato gigapíxel y de operaciones simultáneas de lectura/escritura de datos durante los entrenamientos con nnU-Net y la inferencia con CellViT.

4.1.2. Software y librerías

El desarrollo y ejecución del código se realizó principalmente desde **Visual Studio Code (VSCode)**, un entorno de desarrollo ligero y versátil que permitió la edición remota de archivos mediante extensiones como Remote - SSH. Esta configuración facilitó trabajar directamente sobre el servidor sin necesidad de transferir localmente los archivos ni los modelos.

A nivel de sistema operativo, el entorno de ejecución estaba basado en Ubuntu 20.04 LTS, optimizado para tareas de aprendizaje profundo. La gestión de entornos y dependencias se realizó con Anaconda, permitiendo mantener versiones específicas de librerías para cada módulo del proyecto, lo cual fue especialmente importante para garantizar la compatibilidad con nnU-Net y CellViT. Para ello, dos entornos Conda

fueron creados, uno para entrenar nnU-Net y otro para ejecutar CellViT. Con los paquetes instalados (indicado en el Anexo 1).

4.2. Bases de datos empleadas

4.2.1. CrowdsourcingDataset-Amgadetal2019

La primera base de datos utilizada en este trabajo es el conjunto CrowdsourcingDataset, publicado por Amgad et al. en 2019, el cual forma parte del conocido entorno de análisis The Cancer Genome Atlas (TCGA). Esta base contiene imágenes histopatológicas teñidas con H&E a nivel de portaobjetos completos (WSI), extraídas de muestras de cáncer de mama invasivo. Las imágenes tienen una resolución de 0,25 µm por píxel (microns per pixel, MPP) y están en formato png. En total se utilizaron 151 imágenes en formato png, cada una de las cuales incluye una única región de interés (ROI) anotada manualmente por expertos para identificar la presencia y distribución de TILs. Estas anotaciones permiten generar máscaras de referencia para tareas de segmentación supervisada.

Lo más destacable de esta base de datos es su enfoque en el etiquetado colaborativo: se emplearon técnicas de crowdsourcing con múltiples patólogos expertos para anotar y clasificar diversos tipos celulares, incluyendo linfocitos tumorales [7, 50, 54].

La base de datos incluye (Figura 5):

- Múltiples imágenes WSIs por paciente, escaneadas a distintas resoluciones.
- Anotaciones manuales de núcleos celulares (tipo y localización) en regiones seleccionadas de la imagen, correspondientes a parches específicos previamente delimitados. No se anotó la lámina histológica completa, sino únicamente zonas representativas.
- Etiquetas individuales con clasificaciones como inflammatory, epithelial, neoplastic, entre otras (donde nos interesa inflammatory, para el caso de los TILs).

```
|_ annotations : where JSON annotations will be saves for each slide
|_ masks : where the ground truth masks to use for training and validation are saved
|_ images: where RGB images corresponding to masks are saved
```

Figura 5. estructura de carpetas de la base de datos CrowdsourcingDataset-Amgad [54].

La Figura 6 muestra una captura del visor web HistomicsTK, empleado para visualizar y anotar imágenes histológicas completas. En el panel central se observa una lámina teñida con H&E de la base de datos de Amgad et al. (2019), donde se han marcado manualmente distintas zonas del tejido como tumor, necrosis, estroma o linfocitos.

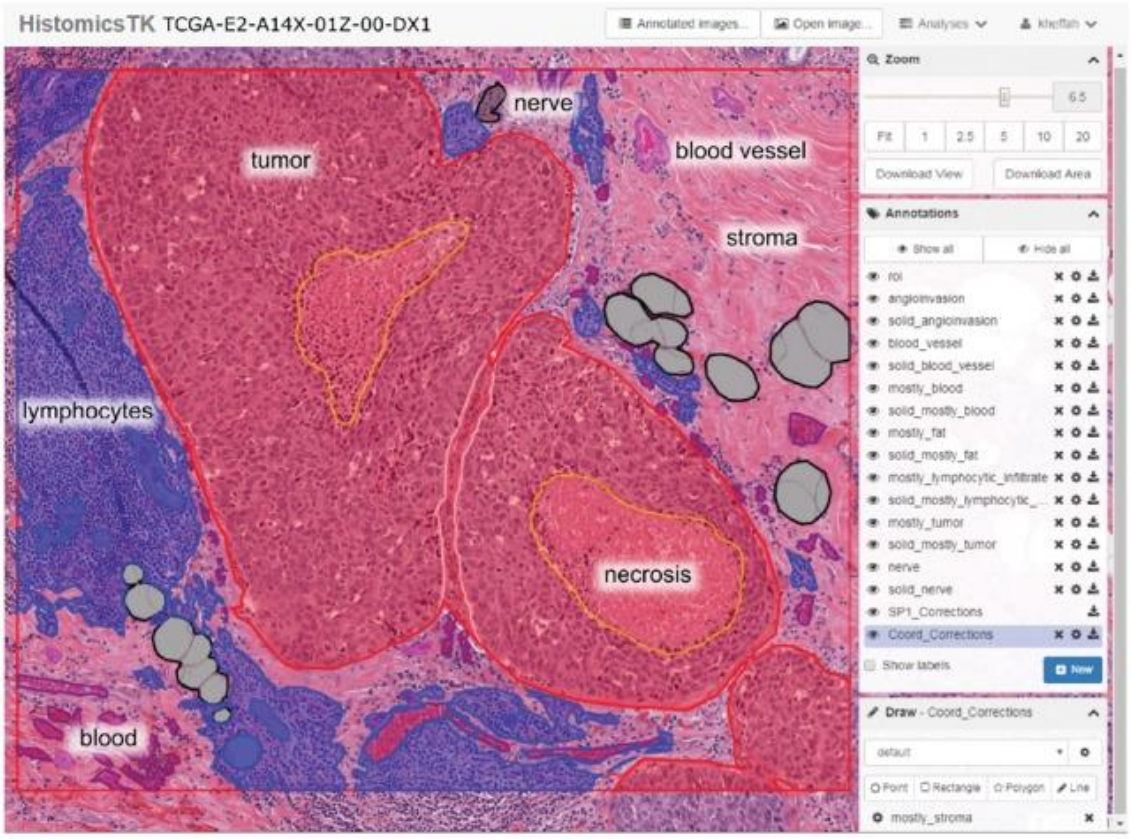


Figura 6. Interfaz de HistomicsTK (obtenida de Amgad et al. en 2019) mostrando anotaciones multiclase sobre una lámina TCGA [7].

Cada región está coloreada de forma distinta, lo que facilita su identificación. En este trabajo, se utilizaron las anotaciones de zonas ricas en linfocitos (como lymphocytes o inflammatory en muchas otras imágenes) para generar máscaras binarias, que luego se procesan para su uso en la detección automática de TILs.

4.2.2. BCSS-WSSS

La base de datos BCSS-WSSS (Breast Cancer Semantic Segmentation – Weakly Supervised Semantic Segmentation) fue introducida por Zhao et al. (2020) como parte del desafío PUMChallenge. Está compuesta por 151 imágenes histológicas WSI, todas teñidas con hematoxilina y eosina H&E y escaneadas a 40 aumentos, procedentes de la

base de datos BCSS original. Teniendo 4986 parches, obtenidos de esas 151 imágenes, de 224×224 píxeles y almacenadas en formato png [51, 52, 53].

Estas imágenes se acompañan de máscaras de segmentación (como se muestra en la Figura 7) generadas automáticamente mediante un método de aprendizaje débilmente supervisado (Weakly Supervised Learning), en el que se entrenó un modelo con anotaciones por imagen (sin segmentaciones manuales) para inferir regiones como tumor, estroma, TILs, necrosis y no tumorales. Aunque estas máscaras no son manuales, presentan un grado aceptable de precisión para tareas de entrenamiento cuando se dispone de recursos limitados o anotaciones expertas escasas [51, 52, 53].

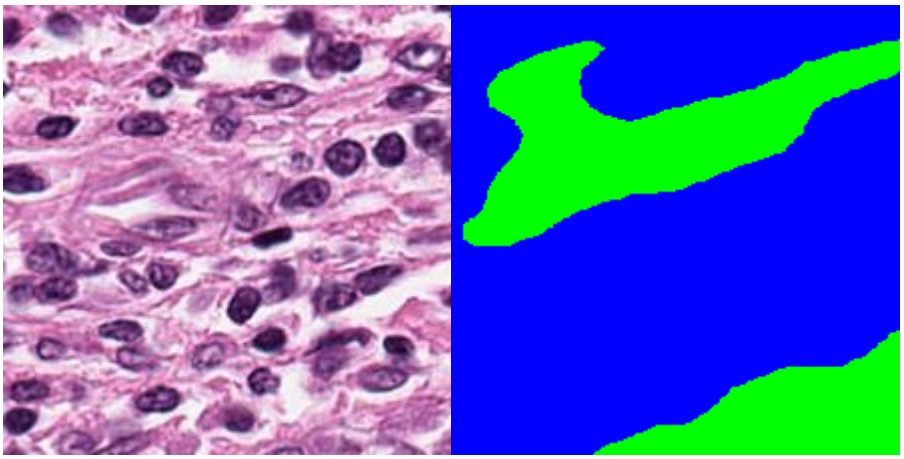


Figura 7. ejemplo de parche de BCSS-WSSS, acompañado de su máscara asociada, en color azul zonas de TILs y en verde la clase estroma.

Como se indica en la Figura 8, hace referencia al código de colores utilizado para representar las distintas clases presentes en las máscaras de segmentación de la base de datos BCSS-WSSS.

```
palette = [0]*15
palette[0:3] = [255, 0, 0]          # Tumor (TUM)
palette[3:6] = [0,255,0]            # Stroma (STR)
palette[6:9] = [0,0,255]            # Lymphocytic infiltrate (LYM)
palette[9:12] = [153, 0, 255]       # Necrosis (NEC)
palette[12:15] = [255, 255, 255]    # White background or exclude
```

Figura 8. código de colores para la segmentación de BCSS-WSSS, tumor en rojo, estroma en verde, TIL en azul, necrosis en violeta, regiones excluidas o fondo en blanco.

Para este trabajo, se han utilizado exclusivamente las máscaras correspondientes a las clases "TIL-rich" (zonas con alta densidad de linfocitos infiltrantes) y "TIL-poor", lo que permite construir un mapa binario claro entre regiones infiltradas y no infiltradas.

Estas máscaras sirvieron como base para el entrenamiento del modelo de segmentación nnU-Net y la posterior validación mediante cohortes externas.

En la Figura 9 se indica la estructura de la base de datos:

```
|_ datasets
|     |_ BCSS-WSSS/
|         |_ train/
|         |_ val/
|             |_ img/
|             |_ mask/
|         |_ test/
|             |_ img/
|             |_ mask/
```

Figura 9. Estructura de carpetas del dataset BCSS-WSSS, organizada en particiones de entrenamiento, validación y prueba, cada una con imágenes y máscaras asociadas. [53]

4.3. Desarrollo del proyecto

El trabajo se ha desarrollado siguiendo las fases mostradas en la Figura 10:

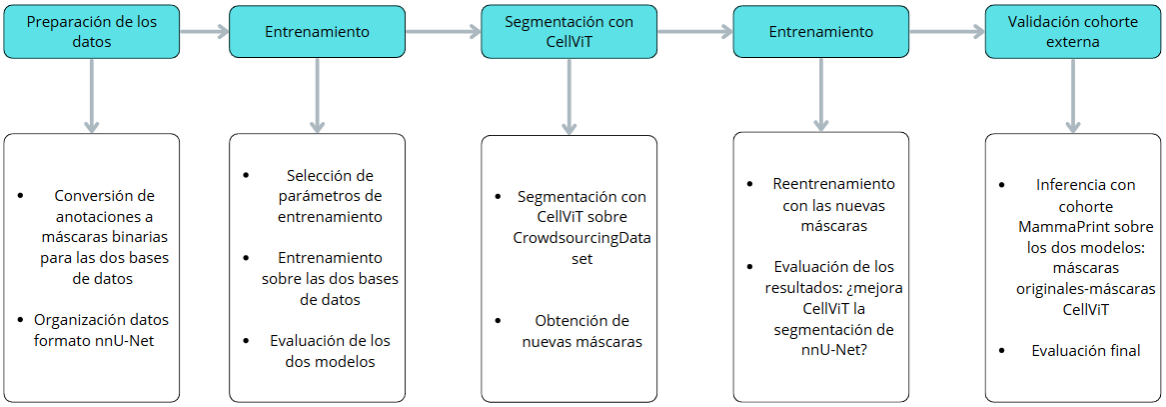


Figura 10. Planificación del flujo de trabajo del proyecto

Tal y como se resume en la Figura 10, el flujo del trabajo se dividió en cinco fases: Desde la preparación inicial de los datos, incluyendo la conversión de anotaciones a máscaras binarias y la organización para su uso con nnU-Net, hasta la comparación final entre modelos, cada fase fue diseñada para construir progresivamente un sistema robusto de segmentación de TILs. La primera parte del trabajo consistió en entrenar un modelo de

segmentación de regiones con TILs con dos bases de datos con anotaciones originales. A continuación, se introdujo CellViT para generar nuevas anotaciones (en este caso de células, no de regiones) pretendiendo mejorar las originales que, tras ser procesadas (obteniendo regiones con TILs), se utilizaron en un segundo entrenamiento. Finalmente, se compararon ambos enfoques para evaluar el impacto de CellViT sobre el rendimiento de nnU-Net y se evaluaron los modelos con la cohorte externa propia llamada MammaPrint del Hospital Universitario Ramón y Cajal.

4.4. Preprocesamiento y preparación de datos

4.4.1. Conversión de anotaciones a máscaras

El preprocesamiento de los datos tiene como finalidad estandarizar y simplificar la información de entrada para los modelos de segmentación, facilitando la identificación automatizada de áreas con TILs. Para ello, se transformaron las anotaciones de las máscaras originales de las bases de datos en **máscaras binarias** que representaran de forma clara las regiones de interés (TILs) frente al resto del tejido.

El procedimiento fue común para ambas bases de datos: se partió de las imágenes histológicas originales junto a sus correspondientes anotaciones o máscaras de segmentación, y se generaron máscaras binarias codificadas con valores de píxel 0 y 1.

- CrowdsourcingDataset: A partir de las clases anatómicas disponibles en las anotaciones (lymphocytes, mostly_lymphocyte_infiltrate), se extrajeron aquellas áreas correspondientes al infiltrado linfocítico. Estas se transformaron en máscaras binarias en las que los píxeles pertenecientes a TILs se marcaron como "1" y el resto como "0".
- BCSS-WSSS: Las máscaras proporcionadas por la base de datos ya incluían regiones positivas para TILs. Se procesaron para convertirlas al formato binario requerido por el modelo, asegurando que el valor "1" representara presencia de infiltrado y "0" el fondo o tejido no infiltrado.

4.4.2. Organización de carpetas

Para poder utilizar nnU-Net en su modo completamente automatizado, es fundamental estructurar los datos siguiendo un esquema de carpetas muy concreto. Esta organización se basa en cuatro carpetas principales, asociadas a distintas fases del flujo de trabajo [38]:

- **"nnUNet_raw"**: contiene los datos originales preparados para el entrenamiento. Dentro de esta carpeta se aloja una subcarpeta (Figura 11) con el nombre DatasetXXX_NAME, donde XXX es un identificador numérico (id) de tres dígitos, y NAME es el nombre del conjunto de datos.



Figura 11. Organización de la carpeta raw nnU-Net

Las imágenes de entrenamiento se encuentran en "imagesTr", las imágenes dedicadas al test (en la validación del modelo) se colocan en "imagesTs" y las máscaras de entrenamiento en "labelsTr". Todo ello siguiendo la configuración de un "dataset.json" que incluye características como el nombre, número de imágenes de entrenamiento, tipo de modalidad (2D) y la codificación de las etiquetas con "0" para "background" y "1" para TIL.

La división entre el conjunto de entrenamiento y test se hace mediante la librería "scikit-learn" usando un 80% de las imágenes para el entrenamiento y un 20% para el conjunto de test. Es una división aleatoria de las imágenes ya que no hay datos clínicos para poder hacer una estratificación. Esta división se ha hecho igual para ambas bases de datos usadas para entrenar los modelos.

- **"nnUNet_preprocessed"**: almacena los datos una vez han sido preprocesados por la nnU-Net. Es fundamental que esta carpeta esté ubicada en un sistema de almacenamiento rápido, ya que es consultada intensivamente durante el entrenamiento.
- **"nnUNet_trained_models"**: guarda los pesos y puntos de control de los modelos generados tras el entrenamiento.
- **"nnUNet_predicted"**: carpeta creada manualmente en este proyecto para almacenar las segmentaciones generadas en la fase de inferencia automática tras el entrenamiento, y poder obtener métricas de evaluación de entrenamiento (Dice).

Esta estructura estandarizada es necesaria para que el flujo de trabajo de la nnU-Net identifique correctamente los datos y pueda ejecutarse sin intervención manual.

4.4.3. Renombrado

Para que la nnU-Net reconozca correctamente los datos de entrada, es imprescindible seguir una convención de nombres estandarizada tanto para las imágenes como para las máscaras. Esta convención define el uso de sufijos específicos que identifican el canal de la imagen y la correspondencia con su máscara segmentada [38].

En este trabajo, se empleó un único canal de entrada por imagen, por lo que todas las imágenes deben incluir el sufijo "_0000" antes de la extensión (Figura 12), quedando el nombre en formato:

TCGA-A1-0010_0000: para la imagen.

TCGA-A1-0010.png: para la máscara asociada

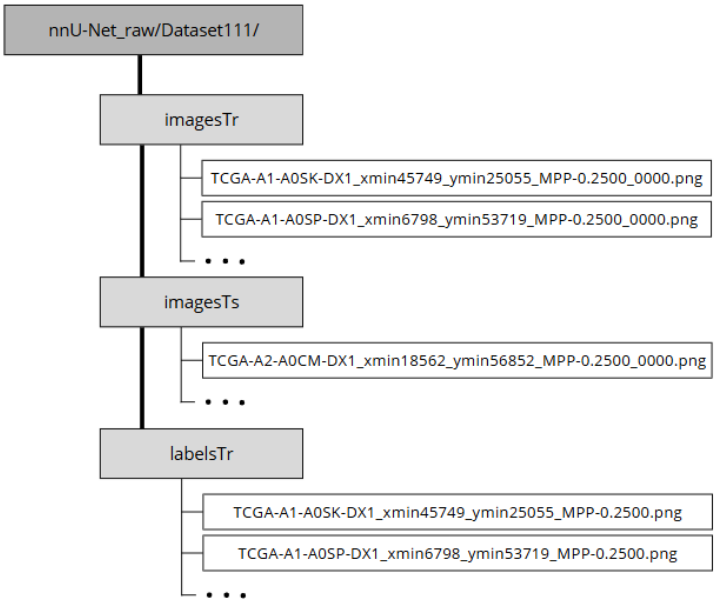


Figura 12. Esquema que deben seguir las carpetas para usar la nnU-Net

4.5. Entrenamiento de los modelos con las máscaras originales

4.5.1. Entrenamiento de la nnU-Net

El primer experimento del proyecto consistió en entrenar el modelo nnU-Net utilizando directamente las imágenes y máscaras binarias de TILs disponibles en las bases de datos seleccionadas. Este entrenamiento sirve como punto de partida para evaluar el rendimiento base del modelo antes de incorporar la segmentación previa mediante CellViT para mejorar las anotaciones originales.

Durante esta fase se realizaron dos entrenamientos independientes, empleando por separado las dos bases de datos: **CrowdsourcingDataset** y **BCSS-WSSS**. En cada caso, se adaptaron las imágenes y máscaras al formato requerido por la nnU-Net como se ha mencionado en el apartado anterior.

Para ello, se siguió el protocolo estándar de entrenamiento de la nnU-Net en 2D, adaptando la estructura de carpetas y el formato de entrada a los requisitos ya comentados. El entrenamiento se llevó a cabo en las GPUs disponibles del servidor del departamento, ajustando los recursos utilizados en función de la carga del sistema.

Lo primero, se definen las variables de las rutas a los directorios clave: “nnUNet_raw”, “nnUNet_preprocessed” y “nnUNet_results”. Estas variables permiten que la red localice correctamente los datos crudos, los archivos preprocesados y el lugar donde se almacenarán los modelos entrenados. Una vez establecida esta configuración, se generó el archivo “dataset.json”, que describe la estructura del conjunto de datos, especificando aspectos como el número de modalidades de entrada, las etiquetas presentes en las máscaras y los nombres de los conjuntos de entrenamiento y validación.

Tras ello, se procedió a la generación de los “fingerprints”, que contienen un resumen estadístico del conjunto de datos (dimensiones, resoluciones, distribución de etiquetas, etc.) y son empleados por la nnU-Net para determinar automáticamente parámetros del preprocesamiento y del entrenamiento. Este conjunto de pasos iniciales garantiza que el flujo de trabajo sea óptimo y se pueda adaptar su arquitectura a las características particulares de cada base de datos.

4.5.1.1. Función de pérdida y parámetros de entrenamiento

Durante el entrenamiento, la nnU-Net ajusta sus pesos iterativamente, es decir, que el modelo aprende poco a poco, realizando muchas actualizaciones sucesivas de sus parámetros internos (llamados pesos) a lo largo de varias épocas, para mejorar su capacidad de segmentar correctamente las regiones de interés en las imágenes. Este ajuste se guía por una función de pérdida (“loss function”), que mide la diferencia entre las predicciones del modelo y las anotaciones reales, permitiendo optimizar el rendimiento del sistema.

En este trabajo, se usa la nnU-Net, que utiliza una función de pérdida compuesta por la suma de dos términos: el coeficiente de Dice suavizado (“Soft Dice Loss”) y la entropía cruzada (“Cross-Entropy Loss”). Esta combinación permite al modelo aprender tanto la forma y la superposición general de las regiones positivas (por medio del Dice) como la clasificación píxel a píxel (por medio de la entropía cruzada), equilibrando así sensibilidad y precisión [62].

La función de pérdida total se expresa como:

$$Ltotal = LDice + LCE$$

Donde “Soft Dice Loss” penaliza las diferencias globales entre las máscaras predicha y real, siendo especialmente útil en casos de clases desbalanceadas como los TILs. Mientras que “Cross-Entropy Loss” mide el error entre la probabilidad de la clase predicha y la clase real para cada píxel, guiando el aprendizaje a nivel local.

Esta función de pérdida conjunta permite que la nnU-Net aprenda segmentaciones más estables y precisas, incluso en imágenes con estructuras pequeñas y poco representadas como los infiltrados linfocíticos.

A continuación, se detallan los principales parámetros de entrenamiento, la configuración empleada y el tiempo estimado de ejecución [62].

- **Tamaño del parche** (“patch size”): el tamaño del parche determina las dimensiones de las subimágenes que se utilizan como entrada en cada iteración del entrenamiento. En el presente trabajo, la nnU-Net seleccionó automáticamente un tamaño de (1536x1024) para las imágenes 2D de la base de datos CrowdsourcingDataset, y un tamaño de (224x224) para la segunda base de datos BCSS-WSSS, en función de las propiedades estadísticas del conjunto de datos (resolución, tamaño medio de imagen y distribución espacial de etiquetas). Este tamaño permite capturar suficiente contexto tisular para segmentar de forma efectiva regiones infiltradas por TILs, sin comprometer la memoria de la GPU.

- **Tamaño de batch** (“batch size”): se estableció un valor de 2 imágenes por iteración, lo cual representa un equilibrio razonable entre consumo de memoria y estabilidad del gradiente. Este valor es el que la nnU-Net ajustó automáticamente en función de la memoria disponible en la GPU utilizada durante el entrenamiento.

- **Número de épocas**: por defecto, nnU-Net realiza 1000 épocas por entrenamiento. Este parámetro fue reducido a 500 épocas, debido a restricciones de tiempo y recursos limitados disponibles, tras comprobar en pruebas preliminares que el modelo alcanzaba una convergencia adecuada con dicha cantidad. Esta decisión permitió reducir significativamente el tiempo total de entrenamiento, manteniendo un rendimiento competitivo en las métricas de validación.

- **Validación cruzada.** En este trabajo no se realizó validación cruzada en sentido estricto, ya que se optó directamente por ejecutar el modelo con la opción “--fold all” de la nnU-Net. Esta configuración entrena un único modelo con la totalidad de los datos de entrenamiento, sin particionarlos en subconjuntos, lo que permite

aprovechar todo el conjunto disponible pero sin la evaluación cruzada clásica. Esta decisión se tomó por limitaciones de tiempo y recursos computacionales.

4.5.2. Evaluación del modelo

Tras finalizar el entrenamiento inicial con la nnU-Net, se procedió a la evaluación del modelo utilizando el conjunto de imágenes de test (20%) definidas en cada base de datos. Esta fase tuvo como objetivo evaluar el rendimiento del modelo entrenado únicamente con las máscaras binarias originales.

La evaluación se realizó empleando el protocolo estándar de nnU-Net, que incluye la predicción sobre los casos de test (en la carpeta "imagesTs") mediante el modo "--fold all". En la evaluación la red nnU-Net inferirá las máscaras binarias de las imágenes de los casos de test, y estás máscaras serán comparadas con las máscaras originales, para obtener la precisión del modelo.

4.5.2.1. Coeficiente de similitud de DICE

Antes de analizar los resultados de los entrenamientos, es fundamental definir la métrica principal empleada para evaluar la calidad de las segmentaciones generadas por el modelo. En este trabajo, se utiliza el coeficiente de similitud de Dice, una métrica ampliamente utilizada en tareas de segmentación médica para cuantificar la similitud entre dos conjuntos, en este caso, entre las máscaras predichas por el modelo y las máscaras de referencia o "ground truth". Este coeficiente toma un valor entre 0 y 1, donde 1 indica una coincidencia perfecta y 0 refleja la ausencia total de superposición.

Matemáticamente, se define como:

$$DICE = \frac{2\,|A \cap B|}{|A| + |B|}$$

Donde, en el caso de este trabajo, A son los píxeles que el modelo ha marcado como TILs, y B son los píxeles que realmente son TILs según la anotación manual.

Esta métrica penaliza tanto los falsos positivos como los falsos negativos, lo que la hace especialmente adecuada para escenarios con clases desbalanceadas, como es el caso de los TILs, donde las regiones positivas suelen ser mucho menores que el fondo. En el presente trabajo, el coeficiente de Dice ha sido la métrica principal para evaluar el rendimiento del modelo nnU-Net en los diferentes experimentos de segmentación binaria.

Durante esta etapa de evaluación del modelo se obtuvieron las métricas de evaluación más relevantes, como el coeficiente Dice y otras medidas derivadas, las cuales permitirán servir de referencia para la comparación con el modelo combinado (CellViT

+ nnU-Net) en fases posteriores del proyecto. Estas métricas también fueron útiles para identificar posibles errores de segmentación, regiones mal clasificadas o limitaciones del entrenamiento con las máscaras originales.

4.6. Segmentación con CellViT

El objetivo principal de la segmentación con CellViT es tratar de mejorar las anotaciones de las máscaras de las bases de datos originales para mejorar los resultados obtenidos. Para ello, fue necesaria la aplicación de CellViT sobre una de las bases de datos originales, para la segmentación automática de TILs a partir de las imágenes histológicas. El objetivo es generar nuevas máscaras binarias a partir de las predicciones del modelo, que posteriormente serán utilizadas como entradas para un segundo entrenamiento con la nnU-Net, evaluando así la utilidad de la segmentación automatizada como paso previo.

4.6.1. Ejecución de CellViT sobre una base de datos

Se seleccionó una de las bases de datos originales (CrowdsourcingDataset) para aplicar el modelo CellViT, previamente descargado y configurado siguiendo las instrucciones oficiales del repositorio [58]. Previamente, las imágenes histológicas se convirtieron al formato ".tif" multipiramidal mediante un script para garantizar la compatibilidad con el sistema de entrada del modelo.

El modelo utilizado fue "CellViT-SAMx40" con AMP activado, el cual combina un "Vision Transformer" con atención espacial adaptativa para segmentación precisa de células, que permite detectar cada una de las células. Este modelo había sido previamente entrenado por los autores sobre una base de datos de segmentación y clasificación de núcleos de imágenes histopatológicas llamada PanNuke, lo que le permite la clasificación según el tipo celular a nivel de cada una de las instancias (células) segmentadas [31, 32, 58].

Para ejecutar la inferencia, se utilizó directamente el punto de control (checkpoint) publicado por los autores, alojado en el repositorio oficial con los pesos preentrenados correspondientes. Las predicciones se realizaron mediante un script que genera un archivo "filelist.txt" con las rutas de las imágenes a procesar, permitiendo aplicar el modelo de forma automatizada sobre la base seleccionada.

La ejecución del modelo CellViT generó un archivo ".geojson" para cada imagen, en el que se identifican y clasifican individualmente las células detectadas en función de su morfología y contexto tisular. Entre las clases posibles, se encuentran células neoplásicas, conectivas, muertas, epiteliales y, especialmente, las células inflamatorias, objetivo

principal de esta fase del proyecto. Se muestra un ejemplo de una imagen segmentada por CellViT en la Figura 13, donde se aprecia la clasificación entre los tipos de células, destacando las inflamatorias:

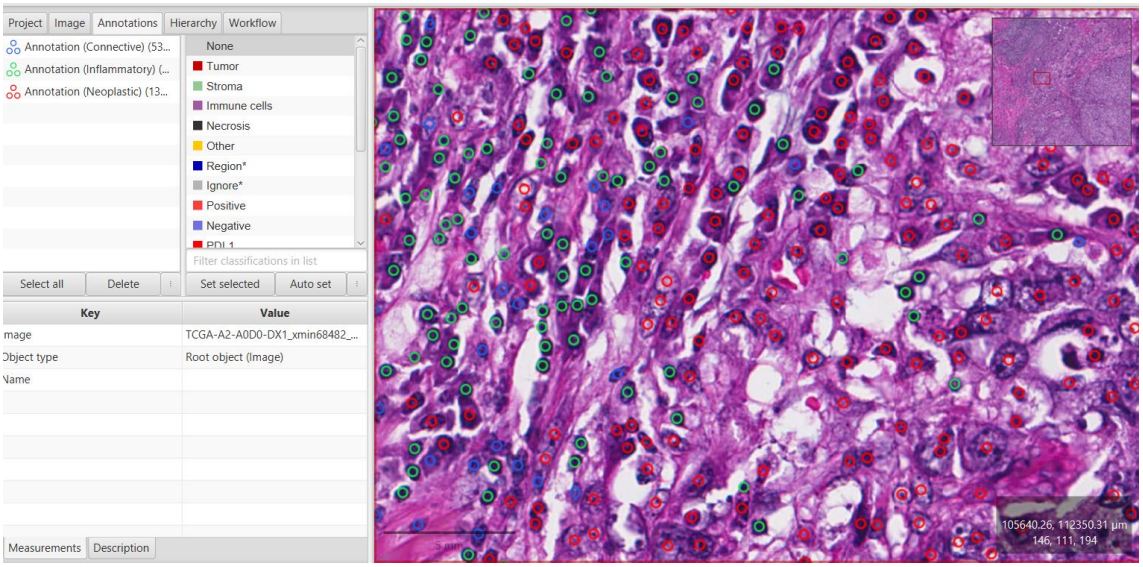


Figura 13. Ejemplo de segmentación de CellViT en una imagen de CrowdsourcingDataset, desde QuPath.

4.7. Generación de máscaras a partir de las segmentaciones de CellViT

Para generar las máscaras binarias de regiones que contienen TILs a partir de las segmentaciones obtenidas por CellViT con anotaciones únicamente celulares y no de regiones, se desarrolló un script en Python que procesa los archivos de salida ".geojson" generados por el modelo. Estos archivos contienen coordenadas del centroide de cada célula clasificadas por tipo, entre ellas los TILs, etiquetados como "Inflammatory".

El proceso para esta conversión se puede resumir en las siguientes acciones, que serán explicadas con profundidad más adelante:

1. **Carga de coordenadas TILs**: Se leen los archivos "*_cell_detection.geojson" y se extraen las coordenadas de los objetos etiquetados como "Inflammatory". Estas coordenadas representan los centroides de células reconocidas como TILs.

2. **Filtrado por densidad**: Con el objetivo de eliminar ruido y aislar regiones con alta concentración de TILs, se calcula la densidad local mediante un radio de búsqueda de 100 píxeles usando un árbol KDTree. Solo se conservan los puntos cuya densidad supere un umbral prefijado (T_density = 0,0003 TILs/pixel^2), representando así regiones biológicamente relevantes con TILs.

3. **Localización en la imagen original**: A partir del nombre del archivo ".geojson", se busca la imagen original de referencia (previamente preprocesada y renombrada en el entorno nnU-Net). Se usa su tamaño para generar una máscara del mismo tamaño.

4. **Creación de máscara de regiones con TILs**: Sobre la máscara vacía se pintan pequeñas circunferencias (radio 2 píxeles) en las ubicaciones filtradas de TILs densos. Posteriormente, se aplican transformaciones morfológicas (dilatación y erosión) con kernels elípticos grandes para fusionar regiones cercanas, suavizar contornos y formar conglomerados que simulan zonas de infiltración linfoide.

5. **Exportación de la máscara**: Finalmente, se genera una imagen binaria en la que las regiones positivas (contienen TILs) aparecen en negro y el fondo en blanco, lo que permite su visualización para analizar los resultados. Estas imágenes se guardan en formato png.

En la Figura 14 se identifican las coordenadas de las células de interés representadas, del paso 1:

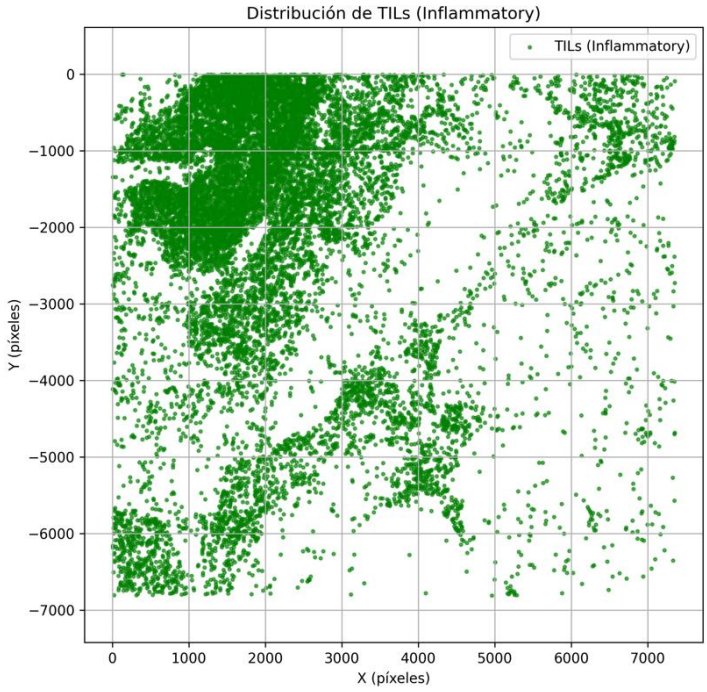


Figura 14. Distribución espacial de los TILs (Inflammatory) detectados por CellViT en una muestra histológica. Cada punto representa el centroide de una célula clasificada como linfocito infiltrante.

El criterio seguido para considerar una región como "infiltrada" se basó en la densidad local de TILs, evaluando el número de células vecinas en un radio de 100 píxeles. Este

valor, definido empíricamente, fue seleccionado tras pruebas visuales sobre la distribución espacial de los puntos segmentados por CellViT, buscando aislar regiones con agrupaciones densas y evitar falsos positivos dispersos.

A partir de las coordenadas de las células etiquetadas como “Inflammatory”, se construyó un KDTree para realizar búsquedas rápidas de vecindad y calcular la densidad área donde hay células vecinas en torno a un área circular de radio R=100 pixeles. Se estableció un umbral mínimo de densidad de 0,0003 TILs/píxel², por debajo del cual se descartaron los puntos.

Una vez identificadas las regiones de TILs densos, se empleó el algoritmo DBSCAN (Density-Based Spatial Clustering of Applications with Noise) para agruparlos en regiones conectadas, sin necesidad de definir el número de clústeres. Esta técnica es especialmente útil para patrones biológicos irregulares y permite distinguir conglomerados reales de ruido. Para cada agrupación, se generó su envolvente convexa (convex hull), que actúa como polígono aproximado de la zona infiltrada.

Estas máscaras iniciales fueron refinadas mediante operaciones morfológicas de dilatación-erosión en OpenCV. Primero, se aplicó una dilatación con un elemento estructurante elíptico de tamaño 100×100 píxeles, que expande las zonas marcadas y conecta agrupaciones próximas. Después, se usó una operación de erosión (“morphological close”) con un kernel de 120×120 para suavizar los bordes, generando así regiones más coherentes y continuas. El resultado final fue una imagen binaria en la que los píxeles pertenecientes a zonas infiltradas se marcaron en negro sobre un fondo blanco.

La Figura 15 muestra el resultado final de las operaciones de dilatación erosión, para la imagen de la Figura 14, realizado en RGB en negro (0,0,0) y en blanco (255,255,255) para su visualización y validación:



Figura 15. Máscara binaria generada a partir de la distribución de TILs, tras aplicar umbralización y operaciones morfológicas (dilatación-erosión).

El resultado final fueron nuevas máscaras binarias con anotaciones de regiones con TILs (que pretenden mejorar las originales), listas para ser utilizadas como etiquetas en un segundo entrenamiento con la nnU-Net, lo que permite evaluar si la segmentación automática de TILs mediante CellViT puede mejorar el rendimiento del modelo en comparación con las máscaras originales.

4.8. Entrenamiento del modelo con las máscaras generadas con CellViT

4.8.1. Reentrenamiento de la red nnU-Net con las máscaras de CellViT

Una vez generadas las nuevas máscaras binarias mediante CellViT++, se reorganizaron los datos para adaptarlos al formato requerido por la nnU-Net y se repitió el proceso de entrenamiento. En este segundo experimento, las segmentaciones automáticas obtenidas con CellViT y retocadas con las regiones de TILs sustituyeron a las máscaras originales de la base de datos. Es importante destacar que se mantuvieron exactamente los mismos parámetros de entrenamiento que en el caso previo (tamaño de parche, batch size, número de épocas, etc.) y se replicó todo el flujo de trabajo, con el fin de asegurar que los resultados fueran comparables de forma directa y cualquier mejora observada pudiera atribuirse exclusivamente a la calidad de las nuevas máscaras generadas por CellViT++.

4.8.2. Evaluación del modelo

La evaluación se hizo de la misma manera que en los primeros entrenamientos, usando la métrica de DICE en los mismos casos en los que se hizo en el entrenamiento de las máscaras originales de esta base de datos para que fuera comparable.

Los resultados obtenidos se compararon con los del modelo base, permitiendo analizar si la integración de segmentaciones generadas por CellViT++ mejora las anotaciones originales y contribuye a una detección más precisa y robusta de las regiones ricas en TILs.

4.9. Inferencia con cohorte externa

Con el objetivo de evaluar la capacidad de generalización del modelo entrenado, se ha llevado a cabo un proceso de inferencia sobre una cohorte externa proveniente de la base de datos MammaPrint del Hospital Universitario Ramón y Cajal, independiente de las utilizadas para entrenamiento. A partir de 15 WSIs, se extrajeron regiones de interés

(ROIs) de 2048×2048 píxeles, como se muestra en el ejemplo de la Figura 16 mediante el software QuPath, seleccionando zonas relevantes con presencia potencial de infiltrado linfocítico.

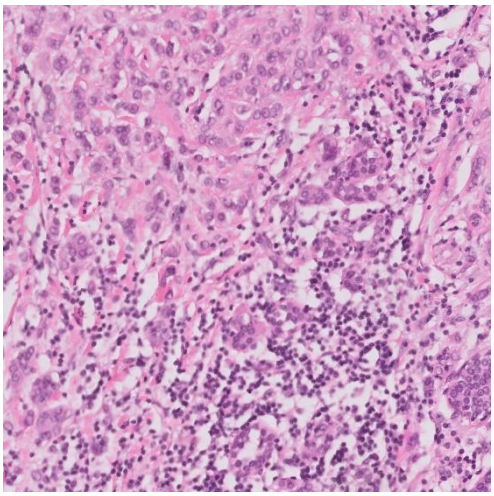


Figura 16. Ejemplo de ROI de 2048x2048 píxeles extraída de WSI MammaPrint

Estas regiones extraídas se exportaron como imágenes individuales en formato png, replicando el mismo procedimiento que se había seguido con los datasets internos. Posteriormente, se generaron los archivos "tiff" necesarios para la segmentación con CellViT++, utilizando el mismo modelo y configuración empleados en experimentos anteriores. Tras la inferencia con CellViT++, se aplicaron operaciones morfológicas de dilatación y erosión para refinar las predicciones y obtener máscaras binarizadas de TILs, donde los píxeles pertenecientes a infiltrado linfocítico se representan en negro (valor 1).

Finalmente, estas máscaras procesadas fueron utilizadas para una validación externa sobre datos completamente independientes de los modelos anteriormente entrenados. De esta forma, se evalúa la robustez de los dos modelos (CrowdsourcingDataset original frente a CrowdsourcingDataset con las máscaras obtenidas de CellViT) cuando se enfrenta a nuevas imágenes no vistas, extraídas de una fuente distinta a la de entrenamiento, reproduciendo fielmente todos los pasos aplicados en los experimentos con la base de datos Crowdsourcing.

5. RESULTADOS

A continuación, se presentan los resultados obtenidos a partir de los diferentes experimentos realizados en este trabajo. Para una mejor organización, se han estructurado en función de las fases clave del proyecto, como se muestra en la Tabla 2. En primer lugar, se muestran los resultados del entrenamiento de la nnU-Net utilizando las máscaras originales de las dos bases de datos empleadas (CrowdsourcingDataset y BCSS-WSSS). Posteriormente, se analiza el impacto de incorporar segmentaciones generadas por CellViT++, combinadas con la nnU-Net, sobre la base de datos Crowdsourcing, para comprobar si las inferencias con CellViT mejoran las anotaciones originales. Finalmente, se presenta una evaluación del modelo entrenado con las anotaciones originales de la base de datos Crowdsourcing y del modelo combinado utilizando en ambos una cohorte externa de imágenes reales del conjunto MammaPrint, comparando ambos resultados. Esta organización permite comparar el rendimiento de cada enfoque y valorar si la incorporación de CellViT mejora los resultados de segmentación del modelo original.

Tabla 2. Resumen de los experimentos realizados, modelos empleados, bases de datos utilizadas y tipo de validación aplicada.

Experimento	Base de datos	Modelo	Validación
1A	CrowdsourcingDataset	nnU-Net	Imágenes de Crowdsourcing + cohorte externa (MammaPrint)
1B	BCSS-WSSS	nnU-Net	Imágenes de BCSS-WSSS
2	CrowdsourcingDataset	CellViT + nnU-Net	Imágenes de Crowdsourcing + cohorte externa (MammaPrint)

5.1. Experimento 1 - Resultados del modelo con las anotaciones originales

5.1.1. Entrenamiento y validación con la base de datos CrowdsourcingDataset

El primer conjunto de resultados corresponde al entrenamiento de la nnU-Net utilizando la base de datos CrowdsourcingDataset (Amgad et al., 2019), compuesta por imágenes histológicas de alta resolución con anotaciones manuales de distintos tipos celulares. Tras adaptar la estructura de carpetas y generar las máscaras binarias necesarias (TILs = 1, resto = 0), se entrenó el modelo siguiendo el protocolo 2D de nnU-Net.

5.1.1.1. Entrenamiento

Como se ha comentado anteriormente, durante el entrenamiento se utilizó un tamaño de parche de (1536x1024), un batch size de 2, y se estableció un máximo de 500 épocas, con una duración de entrenamiento de en torno a 7 horas. La validación se realizó mediante el procedimiento "--fold all".

Durante el entrenamiento el modelo nnU-Net representa tres métricas clave, como se muestran en la gráfica de la Figura 17:

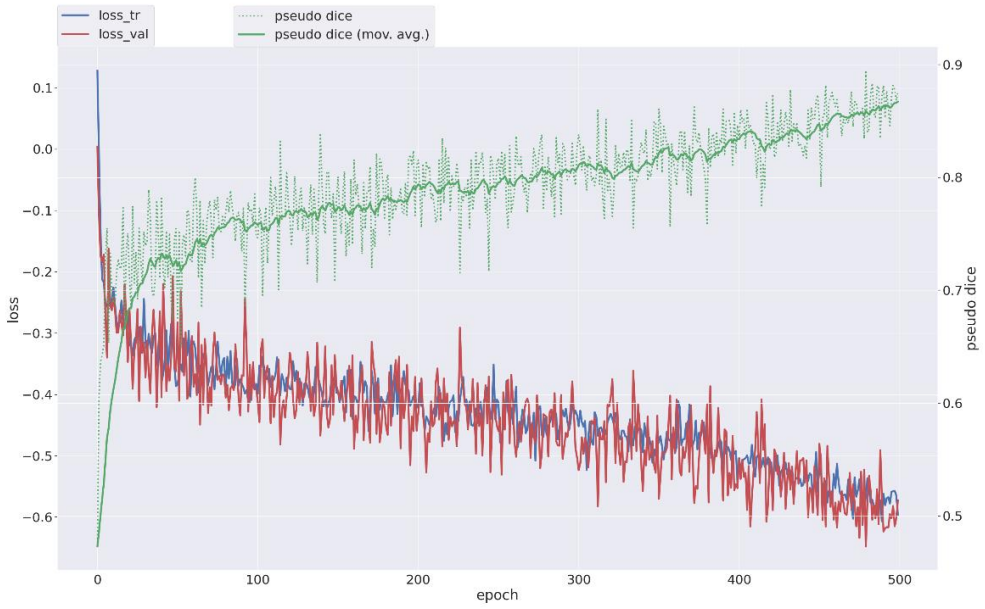


Figura 17. Evolución del entrenamiento de nnU-Net de CrowdsourcingDataset. La línea azul muestra la función de pérdida en entrenamiento, la roja en validación interna, la verde punteada el coeficiente Dice por época y la verde continua su media móvil, reflejando una mejora progresiva.

- **Función de pérdida (Loss) de entrenamiento** (Figura 17-azul) y **de validación** (Figura 17-rojo): ambas disminuyen de forma progresiva, indicando una mejora en la capacidad del modelo para ajustar los datos sin sobreajuste evidente.
- **Coeficiente Dice** (Figura 17-verde punteado): se observa una tendencia ascendente, señalando que el modelo mejora su capacidad de segmentación a lo largo de las épocas.
- **Media móvil del Dice** (Figura 17-verde continuo): suaviza las fluctuaciones del Dice puntual y permite apreciar con claridad la mejora sostenida en el rendimiento.

En conjunto, esta gráfica evidencia una convergencia estable del modelo durante el entrenamiento y una progresiva mejora en la precisión de las segmentaciones.

Sin embargo, es importante destacar que aunque la Figura 17 muestre una evolución positiva durante el entrenamiento (con funciones de pérdida decrecientes y un aumento sostenido del coeficiente Dice), pero estos valores corresponden a la fase de entrenamiento y validación interna del modelo. Por tanto, no garantizan necesariamente un buen rendimiento en datos no vistos (test). Es posible que, al aplicar el modelo sobre nuevos casos, el valor final del Dice disminuya debido a factores como diferencias entre conjuntos o menor representatividad de los datos de validación interna respecto al conjunto real de prueba.

5.1.1.2. Evaluación

Finalizado el entrenamiento del modelo nnU-Net utilizando las máscaras binarias originales de TILs provenientes exclusivamente del conjunto CrowdsourcingDataset, se procedió a evaluar su rendimiento mediante las métricas obtenidas en cada uno de los casos del conjunto de test. El parámetro principal analizado fue el coeficiente de similitud de Dice (Dice Score), utilizado ampliamente en segmentación semántica binaria.

Los resultados muestran una **media de Dice de 0,604**, con una **desviación estándar de 0,25**, lo cual pone de manifiesto una notable variabilidad en el rendimiento del modelo entre las diferentes imágenes. En concreto, el valor máximo alcanzado fue de 0,87, mientras que el mínimo descendió hasta 0,04, lo que indica que la red fue capaz de segmentar correctamente ciertos casos, pero falló significativamente en otros.

Este comportamiento irregular sugiere que las anotaciones originales del dataset podrían contener cierta variabilidad o imprecisión en la delimitación de las regiones infiltradas por TILs, lo que afecta al proceso de aprendizaje del modelo. En consecuencia, aunque un Dice promedio de 0,604 se considera un resultado aceptable para un modelo entrenado con datos histológicos complejos, existe un margen claro de mejora.

Por ello, este primer experimento se considera como una línea base (baseline), que será comparada con los resultados obtenidos al reentrenar el modelo con máscaras generadas automáticamente mediante el enfoque complementario de CellViT++, buscando mejorar la consistencia y calidad de las etiquetas de entrenamiento.

5.1.2. Entrenamiento y evaluación con la base de datos BCSS-WSSS

5.1.2.1. Entrenamiento

Tras los resultados obtenidos en la primera base de datos (CrowdsourcingDataset), donde se observó una elevada variabilidad en el rendimiento del modelo entre distintos casos,

se planteó un segundo experimento con el objetivo de evaluar el rendimiento de la nnU-Net en la tarea de segmentación de regiones con TILs en otra base de datos. Para ello, se recurrió a la base de datos BCSS-WSSS introducida por Zhao et al. (2020) [53] como parte del desafío PUMChallenge.

Como se mencionó, esta base de datos está formada por 151 WSIs, todas H&E y escaneadas a un aumento de 40x. A partir de dichas imágenes, se generó un conjunto de 4986 parches independientes de 224 × 224 píxeles, los cuales fueron almacenados en formato png.

La elección de esta base de datos responde a su mayor número de muestras individuales y su homogeneidad en el tamaño de los parches de 224x224, lo cual se consideró potencialmente beneficioso para incrementar la generalización del modelo y reducir la dispersión de los resultados observada previamente. Se adaptaron los datos siguiendo el mismo protocolo y métricas que en el experimento anterior, con un "batch size" de 2, y se estableció un máximo de 500 épocas, con una duración de entrenamiento de en torno a 6 horas, al igual que la base de datos anterior.

La Figura 18 muestra la evolución de las métricas internas de entrenamiento del modelo nnU-Net sobre la base de datos BCSS-WSSS, utilizando 4986 parches de 224×224 píxeles:

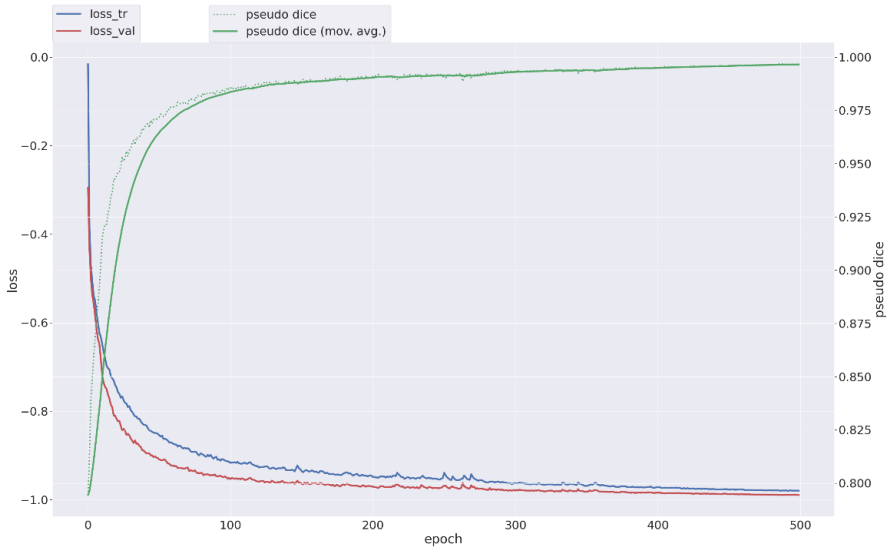


Figura 18.. Evolución del entrenamiento de nnU-Net de BCSS-WSSS. La línea azul indica la función de pérdida en entrenamiento, la roja en validación interna, la verde punteada el coeficiente Dice por época y la verde continua su media móvil, mostrando una rápida y sostenida mejora en la segmentación.

Comparando la evolución del entrenamiento con la base de datos **BCSS-WSSS** respecto a **CrowdsourcingDataset**, se observa una mejora notable en la rapidez y estabilidad del aprendizaje. La pérdida de entrenamiento y validación disminuyen de forma más

pronunciada, y el coeficiente Dice asciende rápidamente hasta estabilizarse, lo que refleja un ajuste más eficiente. Esta diferencia se atribuye a que BCSS-WSSS contiene parches más homogéneos, facilitando un aprendizaje más rápido que las imágenes más variables del conjunto Crowdsourcing. Sin embargo, estas métricas corresponden a la validación interna del modelo y no garantizan su rendimiento sobre datos no vistos.

5.1.2.2. Evaluación

Tras el entrenamiento del modelo nnU-Net utilizando las máscaras binarias de la base de datos BCSS-WSSS, se procedió a evaluar su rendimiento en el conjunto de imágenes de test mediante el coeficiente de similitud de Dice, siguiendo el mismo protocolo descrito en el apartado anterior. Esta evaluación permite analizar la capacidad de generalización del modelo bajo las condiciones específicas de esta base de datos, caracterizada por un mayor número de imágenes, pero de tamaño reducido (224×224 píxeles) y con anotaciones generadas mediante segmentación automática débilmente supervisada.

Los resultados obtenidos muestran una **media de Dice de 0,622**, con una **desviación estándar de 0,326**, lo que refleja, de nuevo, una alta variabilidad en el desempeño del modelo entre diferentes imágenes. En algunos casos, el modelo alcanzó valores de Dice altos (máximo = 0,92), mientras que en otros no logró detectar correctamente las regiones objetivo (Dice = 0,00).

5.1.3. Comparación de resultados entre ambas bases de datos

Al comparar los resultados de BCSS-WSSS (0,622 ± 0,326) con los obtenidos en el experimento previo con CrowdsourcingDataset (0,604 ± 0,25), se observa una ligera mejora en la media, aunque también un incremento en la dispersión de los resultados, como muestra la Figura 19. Esto puede deberse a la propia naturaleza de las anotaciones en BCSS-WSSS, que, aunque más homogéneas en formato, no son manuales, lo que puede introducir incertidumbre en la supervisión del modelo.

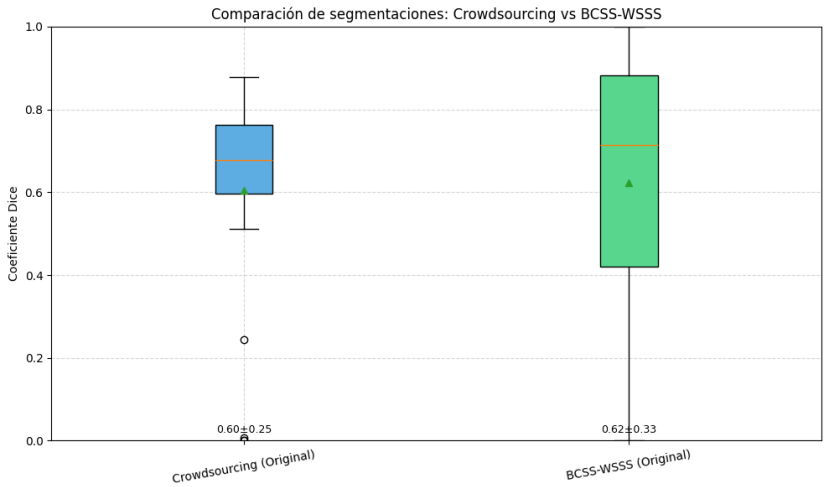


Figura 19. Representación Boxplot de los resultados DICE y desviación por cada caso, para ambos modelos Crowdsourging y BCSS-WSSS.

En resumen, el rendimiento global es comparable para las dos bases de datos, y aunque el modelo logra segmentaciones precisas en muchas imágenes, la elevada variabilidad sugiere que sigue existiendo margen de mejora en la calidad de las máscaras empleadas para el entrenamiento. Esta evaluación refuerza la necesidad de explorar enfoques más robustos, como la incorporación de segmentaciones refinadas mediante modelos como CellViT++. Se seleccionó CrowdsourcingDataset para aplicar CellViT++ porque, al presentar un rendimiento inicial ligeramente inferior y menos disperso (Dice medio de 0,604 ± 0,24), ofrecía un escenario más controlado y sensible para evaluar el impacto de las mejoras introducidas por el modelo, además de ser imágenes más grandes donde CellViT puede tener un rendimiento mayor a la hora de segmentar.

5.2. Experimento 2 - Resultados del modelo combinado con CellViT

5.2.1. Resultados de segmentación de TILs con CellViT sobre la base de datos CrowdsourcingDataset

Para llevar a cabo el segundo experimento, se aplicó el modelo **CellViT++** sobre la base de datos **CrowdsourcingDataset**, con el objetivo de obtener nuevas segmentaciones automáticas de TILs (que mejoraran las originales) que sirvieran como referencia en un segundo entrenamiento con la nnU-Net. Esta decisión se tomó considerando que las anotaciones manuales de dicha base presentaban mayor calidad y coherencia respecto a la BCSS-WSSS al tener menos variación de resultados en cada imagen, lo cual permitía una mejor comparación con las segmentaciones generadas automáticamente.

CellViT++ permitió detectar y clasificar células inflamatorias a partir de las imágenes histológicas originales (Figura 20), sin necesidad de realizar un entrenamiento adicional, gracias a sus pesos preentrenados en grandes conjuntos de datos histopatológicos. A partir de las coordenadas de estas células, se calcularon regiones densamente infiltradas mediante un filtro por densidad local (Figura 21). Posteriormente, dichas zonas se transformaron en máscaras binarias mediante operaciones morfológicas de agrupación y dilatación (Figura 22).

El resultado fue un conjunto de máscaras que definían de forma automatizada regiones enriquecidas en TILs, las cuales fueron posteriormente utilizadas para reentrenar el modelo nnU-Net. Visualmente, se observó que las segmentaciones obtenidas con CellViT presentaban una mejor coherencia espacial y continuidad en comparación con algunas máscaras manuales fragmentadas o incompletas (Figura 22). Esto sugiere que la incorporación de segmentaciones celulares automatizadas puede aportar mayor consistencia en el proceso de entrenamiento del modelo.

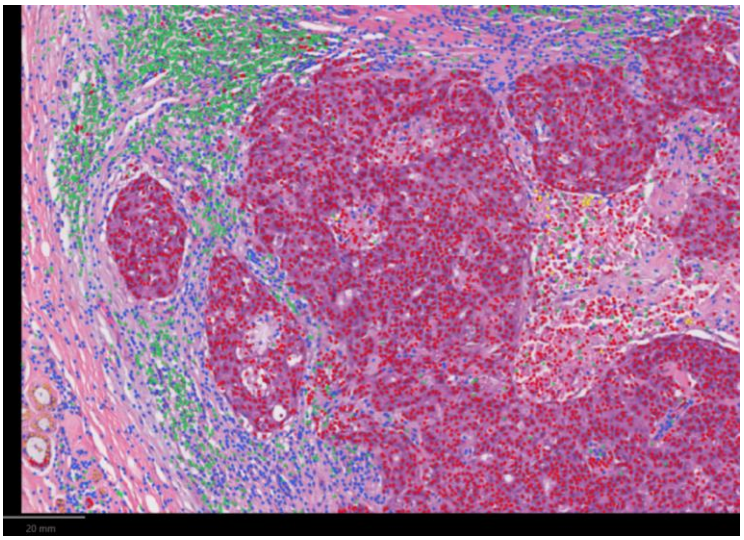


Figura 20. Imagen segmentada con CellViT. Las células en verde corresponden a las inflamatorias (TILs).

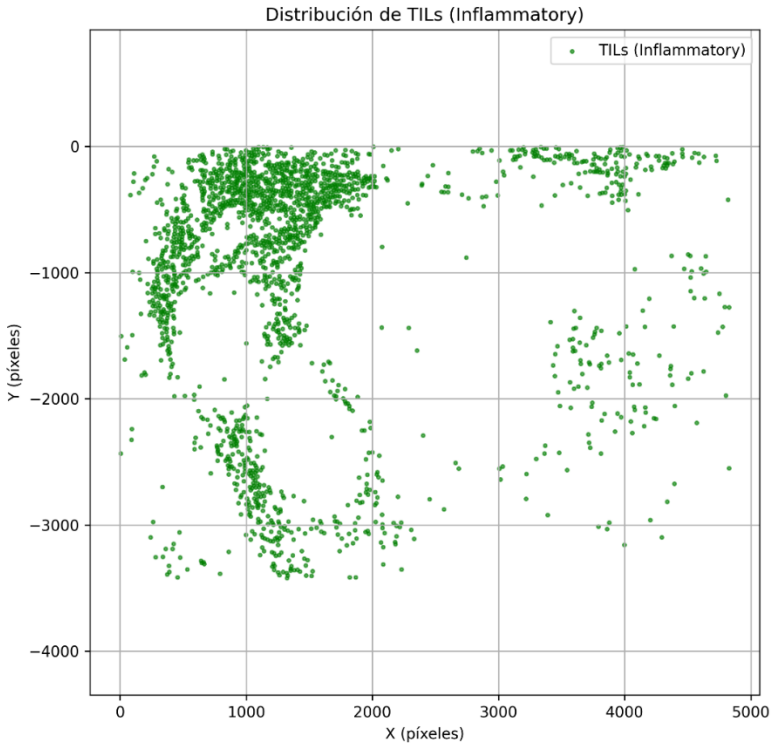


Figura 21. Mapa de distribución de TILs.



Figura 22. Comparación visual entre la segmentación de TILs realizada con CellViT (izquierda) y la máscara original de la base de datos (derecha). Se observa una mejora en la continuidad, cohesión y delimitación precisa de las regiones infiltradas.

En términos cualitativos y a simple vista, los resultados obtenidos con CellViT superan a las máscaras originales. Mientras que la máscara original presenta regiones fragmentadas, contornos imprecisos y una representación más dispersa de los TILs, la segmentación generada con CellViT muestra áreas más compactas, homogéneas y biológicamente coherentes, tal y como enseña la Figura 23.

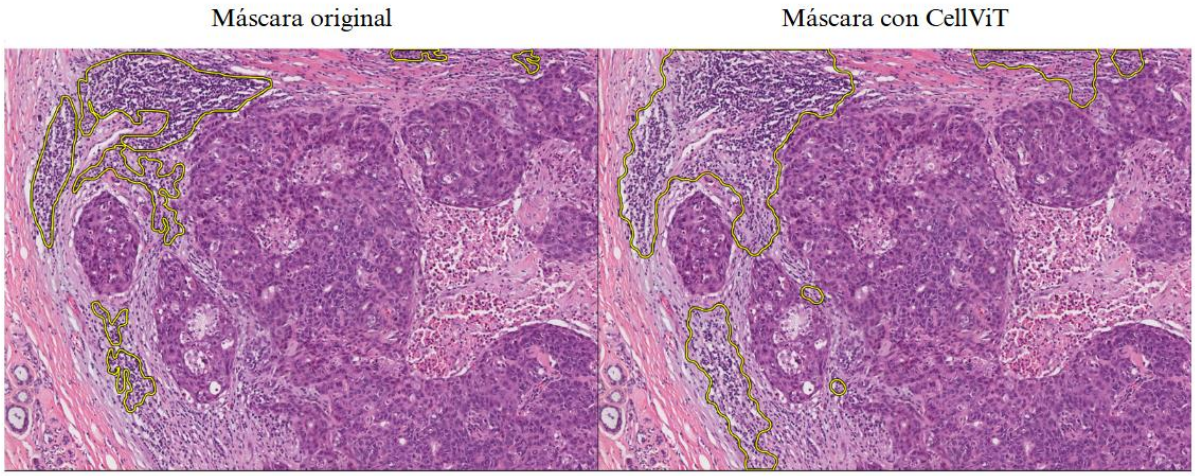


Figura 23. Comparación visual entre la segmentación original (izquierda) y la generada mediante CellViT (derecha) sobre una misma imagen.

5.2.2. Reentrenamiento de la nnU-Net con las nuevas máscaras

Al igual que con el entrenamiento de la base de datos de CrowdsourcingDataset con las máscaras originales, se utilizó un tamaño de parche de (1536x1024), un batch size de 2 y un máximo de 500 épocas. La duración del entrenamiento estuvo en torno a 7 horas. La Figura 24 muestra los resultados durante el entrenamiento, antes de la evaluación.

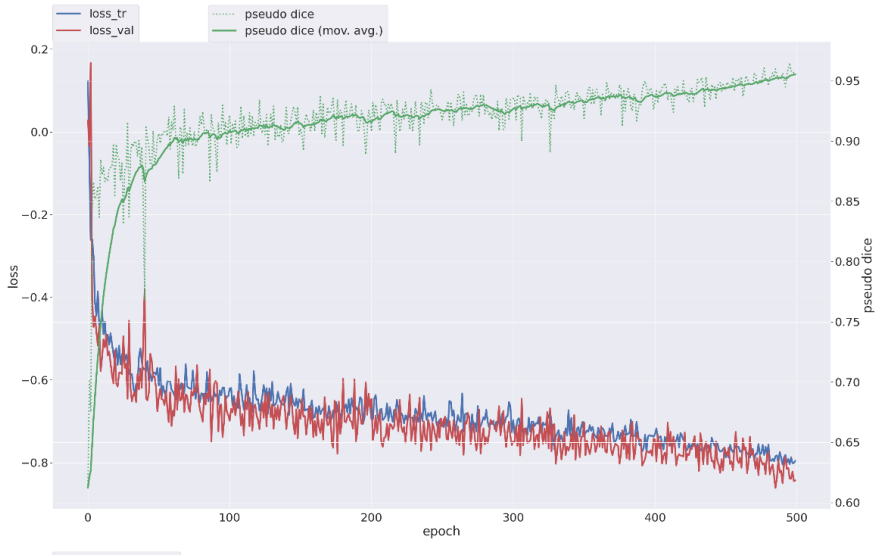


Figura 24. Evolución del entrenamiento de nnU-Net en el modelo de CrowdsourcingDataset combinado con CellViT.

En conjunto, estos resultados muestran una mejora clara respecto al entrenamiento sin CellViT (Figura 17). La inclusión de segmentaciones generadas automáticamente permitió al modelo aprender sobre etiquetas más coherentes y homogéneas, reduciendo el ruido y la variabilidad asociada a las anotaciones manuales.

Como consecuencia, el modelo no solo ajusta mejor los datos durante el entrenamiento y parece que aprende mejor y más rápido, sino que también obtiene un coeficiente Dice significativamente mayor durante el entrenamiento, apuntando a una mayor precisión en la segmentación de TILs. Esta mejora evidencia el potencial del enfoque combinado para incrementar la calidad de las máscaras y del aprendizaje supervisado en contextos con etiquetas limitadas o de baja consistencia.

5.2.3. Evaluación del modelo combinado

Finalizado el reentrenamiento del modelo nnU-Net utilizando las máscaras generadas automáticamente por CellViT++ a partir del conjunto CrowdsourcingDataset, se procedió a evaluar su rendimiento sobre los casos del conjunto de test. El valor medio del coeficiente de Dice alcanzado fue de **0,804**, con una **desviación estándar de 0,25**, lo que indica una segmentación precisa y consistente en la mayoría de las imágenes. Aunque

sigue existiendo cierta variabilidad entre casos, se observa una mejora clara en la concordancia entre las predicciones del modelo y las regiones reales de TILs, atribuible a la mayor calidad de las nuevas máscaras empleadas durante el entrenamiento.

5.2.4. Comparación frente al modelo base

En comparación con el primer experimento basado en las máscaras originales (media de Dice de 0,604 ± 0,25), el modelo combinado con CellViT++ ha logrado una mejora significativa de 0,20 en la puntuación media de Dice. La Figura 25 muestra la comparativa de los resultados de validación de los dos modelos.

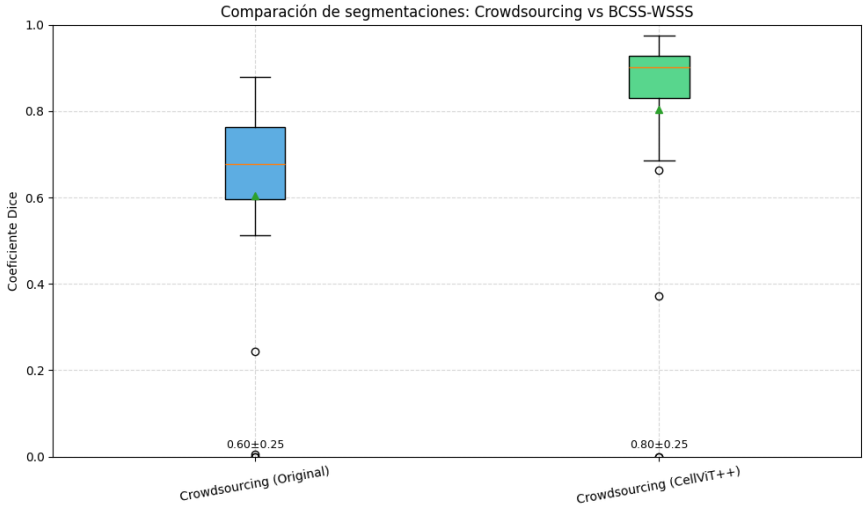


Figura 25. Representación Boxplot de los resultados DICE y desviación por cada caso, para los dos modelos Crowdsourging con las máscaras originales y con CellViT.

Esta mejora pone de manifiesto la efectividad de incorporar segmentaciones refinadas generadas automáticamente, que aportan una mayor coherencia espacial y reducen el ruido presente en las anotaciones manuales, siendo un modelo más consistente. **Por tanto, CellViT++ se presenta como una herramienta útil para fortalecer el proceso de entrenamiento y aumentar la robustez del modelo en entornos histológicos complejos.** En la Figura 26 queda representado la comparación de las predicciones para la misma imagen, en los dos modelos, observándose una segmentación más continua y coherente en la máscara generada por CellViT.

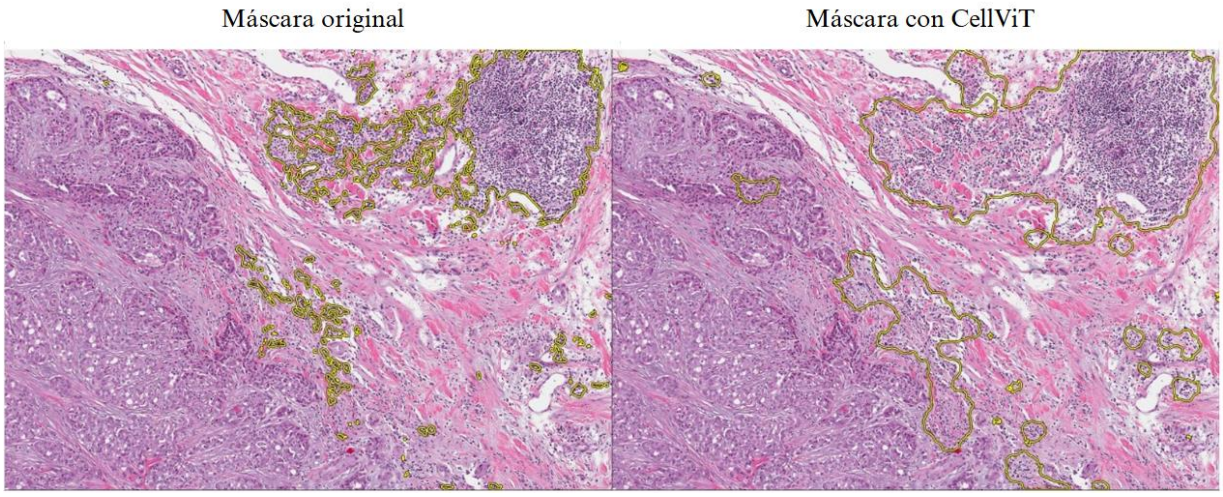


Figura 26. Comparación visual de la predicción en el modelo con las máscaras originales (izquierda) y la generada mediante CellViT (derecha) sobre una misma imagen.

5.3. Evaluación final sobre cohorte externa (MammaPrint)

Para llevar a cabo una validación externa del rendimiento del sistema, se emplearon 15 imágenes WSI H&E procedentes de la base de datos MamaPrint procedentes del Hospital Universitario Ramón y Cajal, a partir de las cuales se extrajeron regiones cuadradas (ROIs) de 2048×2048 píxeles. Estas imágenes fueron evaluadas en los dos modelos entrenados previamente: el modelo base de nnU-Net entrenado con las máscaras originales del CrowdsourcingDataset, y el modelo combinado, entrenado con las máscaras generadas automáticamente mediante CellViT++.

Los resultados obtenidos al aplicar estos modelos sobre la cohorte externa muestran nuevamente una mejora clara a favor del modelo combinado. **El modelo base alcanzó un valor medio de Dice de 0,580 con una desviación estándar de 0,219, mientras que el modelo combinado obtuvo una media de 0,681 con desviación de 0,234**. Esta diferencia de más de 0,10 puntos en la métrica de Dice confirma que el modelo reentrenado con CellViT++ generaliza mejor a datos no vistos, incluso en un entorno externo con imágenes distintas a las del conjunto de entrenamiento, siendo un modelo más consistente.

Estos resultados respaldan la hipótesis planteada en el apartado anterior, donde ya se observaba una mejora de 0,20 en la puntuación media de Dice al evaluar sobre el conjunto Crowdsourcing. En conjunto, la evidencia sugiere que el uso de segmentaciones automáticas refinadas mediante CellViT++ contribuye a generar modelos más robustos, capaces de ofrecer segmentaciones más precisas y consistentes (Figura 27) también en contextos reales ajenos al entrenamiento.

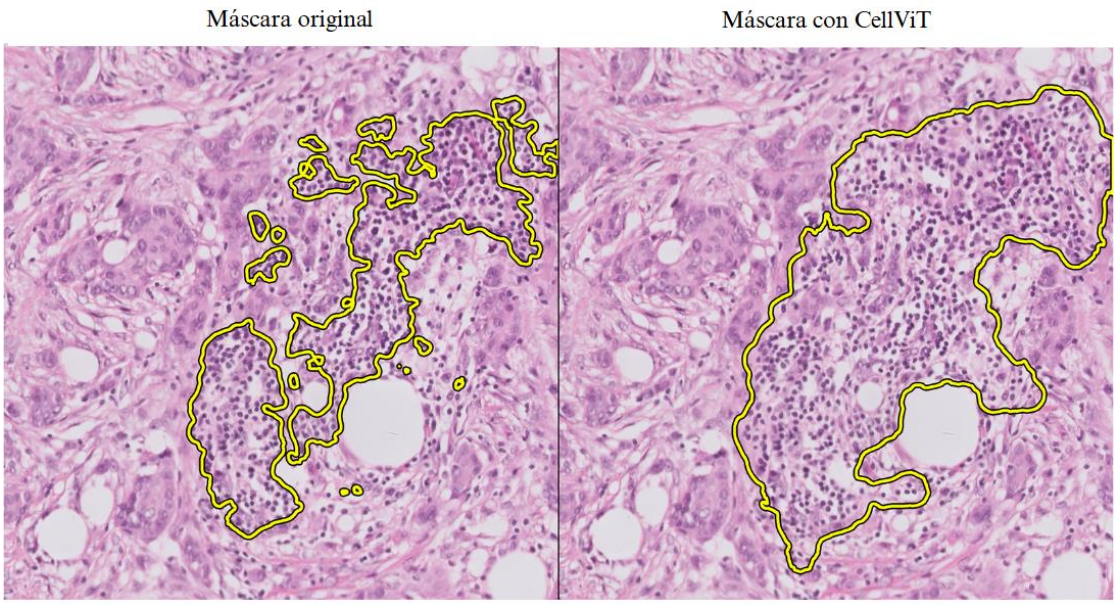


Figura 27. Comparación visual de la predicción en el modelo con las máscaras originales (izquierda) y la generada mediante CellViT (derecha) sobre una misma imagen.

En conclusión, los resultados evidencian una mejora en el rendimiento del modelo al incorporar las máscaras generadas por CellViT en una cohorte externa (Figura 28), lo que refuerza la utilidad de este enfoque para datos reales no vistos.

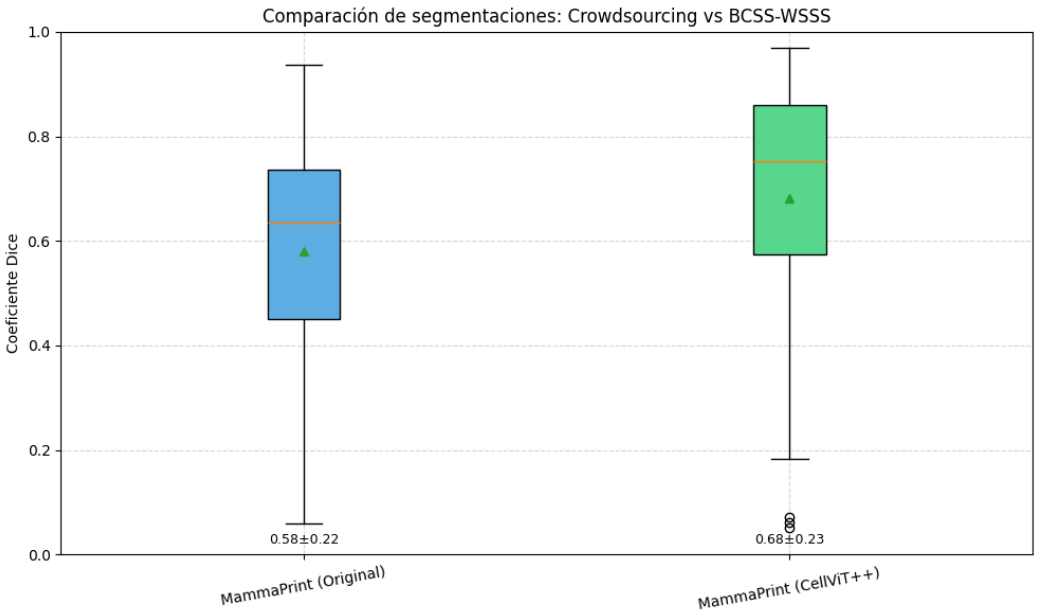


Figura 28. Representación Boxplot de la inferencia sobre una cohorte externa de los dos modelos de Crowdsourcing con las máscaras originales y creadas por CellViT.

En la Tabla 3 se resumen los resultados de cada modelo:

Tabla 3. Resultados de los DICE para los cinco modelos

Modelo	Dice
Crowdsourcing (original)	0,60 ± 0,25
BCSS-WSSS (original)	0,62 ± 0,33
Crowdsourcing + CellViT	0,80 ± 0,25
Mammaprint (original)	0,58 ± 0,22
Mammaprint (CellViT)	0,68 ± 0,23

Los resultados representados en la Tabla 3 reflejan claramente una mejora general en el rendimiento de segmentación al incorporar predicciones generadas por CellViT++. En particular, se observa un aumento notable en el coeficiente Dice tanto en la cohorte de Crowdsourcing como en la de MammaPrint cuando se utilizan máscaras generadas por el modelo CellViT++ en lugar de las originales. Esta mejora se manifiesta no solo en el valor medio, sino también en una menor dispersión en el caso de Crowdsourcing (CellViT++), lo que sugiere una mayor consistencia del modelo. La cohorte BCSS-WSSS, utilizada como referencia, muestra una mayor variabilidad, posiblemente asociada a la heterogeneidad del conjunto. En conjunto, estos resultados apoyan la utilidad de CellViT++ como herramienta para enriquecer datasets limitados o de calidad subóptima, mejorando el entrenamiento de modelos supervisados como nnU-Net.

6. Conclusiones y perspectivas futuras

Este Trabajo Fin de Grado ha demostrado la viabilidad de aplicar técnicas avanzadas de aprendizaje profundo para la segmentación automática de regiones enriquecidas en linfocitos infiltrantes tumorales en WSI teñidas con H&E de cáncer de mama. La utilización de arquitecturas como nnU-Net y modelos preentrenados como CellViT++ ha permitido superar algunas de las limitaciones tradicionales asociadas a la evaluación manual, mejorando la precisión, reproducibilidad y escalabilidad del análisis de TILs en entornos clínicos.

Los resultados obtenidos reflejan una mejora significativa en el rendimiento del modelo, siendo más consistente, al incorporar segmentaciones generadas automáticamente mediante CellViT++, evidenciada por un incremento de más de 0,20 puntos en el coeficiente Dice medio respecto al modelo base entrenado con anotaciones manuales. Esta mejora también se ha mantenido en la validación externa sobre la cohorte MammaPrint, donde el modelo combinado alcanzó una media de Dice superior a la obtenida con el modelo original, lo cual respalda su capacidad de generalización y su aplicabilidad en escenarios reales con datos no vistos.

En concreto, las comparaciones entre el modelo entrenado con máscaras originales y el modelo combinado con CellViT++ han mostrado mejoras tanto en las bases públicas (Crowdsourcing y BCSS-WSSS) como en la cohorte externa, reflejando una segmentación más continua y coherente. Estas diferencias fueron especialmente notables en las regiones periféricas de las infiltraciones, donde CellViT++ permitió captar contornos más amplios y homogéneos, favoreciendo una mejor representación de las áreas enriquecidas en TILs.

Además de los avances técnicos logrados, este trabajo contribuye a consolidar una metodología robusta para la integración de datos histológicos y modelos de segmentación celular, gracias a la automatización de la identificación de biomarcadores inmunológicos clave como los TILs. Esta automatización representa un paso relevante hacia la implementación de sistemas de apoyo al diagnóstico en patología digital, facilitando una evaluación más objetiva, consistente y rápida, especialmente en el contexto de la medicina de precisión.

No obstante, el desarrollo llevado a cabo también ha puesto de manifiesto una serie de limitaciones que abren nuevas líneas de investigación. Entre ellas, cabe destacar que la dependencia de bases de datos bien anotadas sigue siendo un factor limitante para la generalización de los modelos, por lo que futuras investigaciones podrían explorar estrategias basadas en aprendizaje semi-supervisado o auto-supervisado, capaces de aprovechar grandes volúmenes de datos no etiquetados.

En cuanto a las aplicaciones clínicas, la vía con mayor potencial es la integración de la información que extraen los modelos a partir de las imágenes histológicas con datos genéticos como los que proporciona el test de MammaPrint. Poder combinar la segmentación automática de TILs con los perfiles de expresión génica permitiría cuantificar aún más la clasificación del riesgo MammaPrint, sobre todo en pacientes con resultados intermedios o poco claros. A partir de los resultados obtenidos, una línea futura especialmente relevante sería calcular de forma cuantitativa el porcentaje de área ocupada por TILs en las imágenes y analizar su posible relación con el riesgo de recurrencia estimado por el perfil genómico. Este análisis podría contribuir a una mejor interpretación del riesgo y aumentar el valor clínico del sistema desarrollado.

Por último, otra posible línea futura sería aplicar esta misma metodología propuesta a otros tipos de cáncer, como el de pulmón o el melanoma, donde la evaluación inmunológica del microambiente tumoral también desempeña un papel crucial. La generalización del enfoque basado en CellViT++ y nnU-Net, junto con la adaptación a nuevas modalidades de imagen o sistemas de anotación, permitirá validar su utilidad en un espectro más amplio de patologías oncológicas.

En conjunto, este proyecto sienta una base sólida para el desarrollo de sistemas automáticos que ayuden a detectar biomarcadores inmunológicos como los TILs en imágenes reales de pacientes. Además, abre la puerta a seguir avanzando en soluciones que no solo segmenten de manera automatizada y precisa, sino que también se puedan interpretar, aplicar a otros tipos de cáncer y usar como complemento en herramientas pronósticas como MammaPrint, facilitando así una medicina más precisa y adaptada a cada caso.

7. BIBLIOGRAFÍA

[1] H. Sung *et al.*, "Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality," *CA Cancer J. Clin.*, vol. 71, no. 3, pp. 209–249, 2021. doi: 10.3322/caac.21660

[2] S. Łukasiewicz *et al.*, "Breast cancer—An updated review," *Cancers*, vol. 13, no. 17, p. 4287, 2021. doi: 10.3390/cancers13174287

[3] A. Fiorin *et al.*, "Review of TIL datasets in breast cancer AI research," *J. Digit. Imaging Inform. Med.*, vol. 37, pp. 2996–3008, 2024. doi: 10.1007/s10278-024-01043-8

[4] S. Loi *et al.*, "TILs are prognostic in TNBC and predictive for trastuzumab benefit," *Ann. Oncol.*, vol. 25, no. 8, pp. 1544–1550, 2014. doi: 10.1093/annonc/mdu112

[5] S. Hendry *et al.*, "Assessing TILs in solid tumors: A review for pathologists," *Adv. Anat. Pathol.*, vol. 24, no. 6, pp. 311–335, 2017. doi: 10.1097/PAP.0000000000000161

[6] J. Saltz *et al.*, "Spatial organization of TILs via deep learning in pathology images," *Cell Rep.*, vol. 23, no. 1, pp. 181–193.e7, 2018. doi: 10.1016/j.celrep.2018.03.086

[7] M. Amgad *et al.*, "Structured crowdsourcing enables convolutional segmentation of histology images," *Bioinformatics*, vol. 35, no. 18, pp. 3461–3467, 2019. doi: 10.1093/bioinformatics/btz083

[8] L. J. Van't Veer *et al.*, "Gene expression profiling predicts clinical outcome of breast cancer," *Nature*, vol. 415, no. 6871, pp. 530–536, 2002. doi: 10.1038/415530A

[9] F. Cardoso *et al.*, "70-gene signature as an aid to treatment decisions in early-stage breast cancer," *N. Engl. J. Med.*, vol. 375, no. 8, pp. 717–729, 2016. doi: 10.1056/NEJMOA1602253

[10] M. Arnold *et al.*, "Current and future burden of breast cancer: Global statistics for 2020 and 2040," *Breast*, vol. 66, pp. 15–23, 2022. doi: 10.1016/j.breast.2022.08.010

[11] C. Denkert *et al.*, "Tumor-associated lymphocytes as an independent predictor of response to neoadjuvant chemotherapy in breast cancer," *J. Clin. Oncol.*, vol. 28, no. 1, pp. 105–113, 2010. doi: 10.1200/JCO.2009.23.7370

[12] S. Li *et al.*, "Predictive and prognostic values of tumor infiltrating lymphocytes in breast cancers treated with neoadjuvant chemotherapy: A meta-analysis," *Breast*, vol. 66, pp. 97–109, 2022. doi: 10.1016/j.breast.2022.10.001

[13] C. Criscitiello *et al.*, "A gene signature to predict high tumor-infiltrating lymphocytes after neoadjuvant chemotherapy and outcome in patients with triple-negative breast cancer," *Ann. Oncol.*, vol. 29, no. 1, pp. 162–169, 2018. doi: 10.1093/annonc/mdx691

[14] C. Herrero-Vicent *et al.*, "Predictive and prognostic impact of tumour-infiltrating lymphocytes in triple-negative breast cancer treated with neoadjuvant chemotherapy," *Ecancermedicalscience*, vol. 11, 2017. doi: 10.3332/ecancer.2017.759

[15] S. Adams *et al.*, "Prognostic value of tumor-infiltrating lymphocytes in triple-negative breast cancers from two phase III randomized adjuvant breast cancer trials: ECOG 2197 and ECOG 1199," *J. Clin. Oncol.*, vol. 32, no. 27, pp. 2959–2966, 2014. doi: 10.1200/JCO.2013.55.0491

[16] C. Denkert *et al.*, "Tumour-infiltrating lymphocytes and prognosis in different subtypes of breast cancer: a pooled analysis of 3771 patients treated with neoadjuvant therapy," *Lancet Oncol.*, vol. 19, no. 1, pp. 40–50, 2018. doi: 10.1016/S1470-2045(17)30904-X

[17] V. Kotoula *et al.*, "Tumors with high-density tumor infiltrating lymphocytes constitute a favorable entity in breast cancer: a pooled analysis of four prospective adjuvant trials," *Oncotarget*, vol. 7, no. 4, pp. 5074–5087, 2016. doi: 10.18632/oncotarget.6231

[18] C. Valenza *et al.*, "Tumor infiltrating lymphocytes across breast cancer subtypes: Current issues for biomarker assessment," *Cancers*, vol. 15, no. 3, p. 767, 2023. doi: 10.3390/cancers15030767

[19] M. O'Loughlin *et al.*, "Reproducibility and predictive value of scoring stromal tumour infiltrating lymphocytes in triple-negative breast cancer: a multi-institutional study," *Breast Cancer Res. Treat.*, vol. 171, no. 1, 2018. doi: 10.1007/s10549-018-4825-8

[20] S. E. Stanton, S. Adams, and M. L. Disis, "Variation in the incidence and magnitude of tumor-infiltrating lymphocytes in breast cancer subtypes: A systematic review," *JAMA Oncol.*, vol. 2, no. 10, pp. 1354–1360, 2016. doi: 10.1001/jamaoncol.2016.1061

[21] S. Abousamra *et al.*, "Deep learning-based mapping of tumor infiltrating lymphocytes in whole slide images of 23 types of cancer," *Front. Oncol.*, vol. 11, p. 806603, 2022. doi: 10.3389/fonc.2021.806603

[22] X. Zhang *et al.*, "SAMS-Net: Fusion of attention mechanism and multi-scale features network for tumor infiltrating lymphocytes segmentation," *Math. Biosci. Eng.*, vol. 20, no. 2, pp. 2964–2979, 2023. doi: 10.3934/MBE.2023140

[23] F. Isensee *et al.*, "nnU-Net: A self-configuring method for deep learning-based biomedical image segmentation," *Nat. Methods*, vol. 18, no. 2, pp. 203–211, 2021. doi: 10.1038/s41592-020-01008-z

[24] M. Yosofvand *et al.*, "Automated detection and scoring of tumor-infiltrating lymphocytes in breast cancer histopathology slides," *Cancers*, vol. 15, no. 14, 2023. doi: 10.3390/cancers15143635

[25] S. Liu *et al.*, "A panoptic segmentation dataset and deep-learning approach for explainable scoring of tumor-infiltrating lymphocytes," *NPJ Breast Cancer*, vol. 10, no. 1, pp. 1–10, 2024. doi: 10.1038/s41523-024-00663-1

[26] N. McConnell *et al.*, "Exploring advanced architectural variations of nnUNet," *Neurocomputing*, vol. 560, p. 126837, 2023. doi: 10.1016/j.neucom.2023.126837

[27] Z. Rauf *et al.*, "Lymphocyte detection for cancer analysis using a novel fusion block based channel boosted CNN," *Sci. Rep.*, vol. 13, no. 1, pp. 1–14, 2023. doi: 10.1038/s41598-023-40581-z

[28] C. Denkert *et al.*, "Tumor-infiltrating lymphocytes and response to neoadjuvant chemotherapy with or without carboplatin in HER2-positive and triple-negative primary breast cancers," *J. Clin. Oncol.*, vol. 33, no. 9, pp. 983–991, 2015. doi: 10.1200/JCO.2014.58.1967

[29] G. Pruneri *et al.*, "Clinical validity of tumor-infiltrating lymphocytes analysis in patients with triple-negative breast cancer," *Ann. Oncol.*, vol. 27, no. 2, pp. 249–256, 2016. doi: 10.1093/annonc/mdv571

[30] F. Hörst *et al.*, "CellViT: Vision transformers for precise cell segmentation and classification," *Med. Image Anal.*, vol. 94, p. 103143, 2024. doi: 10.1016/j.media.2024.103143

[31] F. Hörst *et al.*, "CellViT++: A generalist vision transformer for efficient and robust cell segmentation," *arXiv preprint*, arXiv:2306.15350, 2023. [Online]. Available: https://arxiv.org/abs/2306.15350

[32] J. Gamper *et al.*, "PanNuke Dataset Extension, Insights and Baselines," *arXiv preprint*, arXiv:2003.10778, 2020. [Online]. Available: https://arxiv.org/abs/2003.10778

[33] N. Shahamiri *et al.*, "Cracking the PUMA challenge in 24 hours with CellViT++ and nnU-Net," *arXiv preprint*, arXiv:2503.12269, 2025. doi: 10.48550/arXiv.2503.12269

[34] H. Chen *et al.*, "The PUMA challenge: Panoptic segmentation of melanoma histopathology whole slide images," *Med. Image Anal.*, vol. 89, p. 102845, 2023. doi: 10.1016/j.media.2023.102845

[35] M. van Rijthoven *et al.*, "HookNet: Multi-resolution convolutional neural networks for semantic segmentation in histopathology whole-slide images," *arXiv preprint*, arXiv:2006.12230, 2020. [Online]. Available: https://arxiv.org/abs/2006.12230

[36] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," in *Proc. 2nd Int. Conf. Knowl. Discov. Data Min. (KDD)*, 1996, pp. 226–231.

[37] R. J. Chen *et al.*, "Pathomic Fusion: An integrated framework for fusing histopathology and genomic features for cancer diagnosis and prognosis," *arXiv preprint*, arXiv:1912.08937, 2019. [Online]. Available: https://arxiv.org/abs/1912.08937

[38] MIC-DKFZ, "nnUNetv2," GitHub repository, 2025. Available: https://github.com/MIC-DKFZ/nnunet

[39] Project-MONAI, "MONAI 1.4.0 — What's New," documentation, 2024. Available: https://docs.monai.io

[40] S. van der Walt, S. C. Colbert, and G. Varoquaux, "The NumPy array: A structure for efficient numerical computation," *Comput. Sci. Eng.*, vol. 13, no. 2, pp. 22–30, 2011. doi: 10.1109/MCSE.2011.37

[41] A. Paszke *et al.*, "PyTorch: an imperative style, high-performance deep learning library," *Adv. Neural Inf. Process. Syst.*, vol. 32, pp. 8024–8035, 2019. doi: 10.48550/arXiv.1912.01703

[42] J. D. Hunter, "Matplotlib: a 2D graphics environment," *Comput. Sci. Eng.*, vol. 9, no. 3, pp. 90–95, 2007. doi: 10.1109/MCSE.2007.55

[43] N. Heller, "batchgenerators – A Python framework for data augmentation," *GitHub repository*, 2021. [Online]. Available: https://github.com/MIC-DKFZ/batchgenerators

[44] SimpleITK contributors, *SimpleITK: A simplified interface to the Insight Toolkit (ITK), Version 2.4.1*, 2024. [Online]. Available: https://simpleitk.org

[45] P. Mithun, *dicom2nifti: DICOM to NIfTI converter*, GitHub repository, 2022. [Online]. Available: https://github.com/icometrix/dicom2nifti

[46] E. Brett *et al.*, "NiBabel: accessing a cacophony of neuroimaging file formats," *Front. Neuroinform.*, vol. 8, p. 8, 2014. doi: 10.3389/fninf.2014.00008.

[47] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. doi: 10.5555/1953048.2078195

[48] P. Virtanen *et al.*, "SciPy 1.0: fundamental algorithms for scientific computing in Python," *Nat. Methods*, vol. 17, pp. 261–272, 2020. doi: 10.1038/s41592-019-0686-2.

[49] S. van der Walt et al., "scikit-image: image processing in Python," *PeerJ*, vol. 2, p. e453, 2014. doi: 10.7717/peerj.453

[50] National Cancer Institute, "The Cancer Genome Atlas Program (TCGA)," *NIH Center for Cancer Genomics*, 2024. [Online]. Available: https://www.cancer.gov/ccg/research/genome-sequencing/tcga

[51] T. Zhao, A. Javed, M. A. Khan, et al., “Breast cancer histopathological image classification using a hybrid deep CNN model,” *Sensors*, vol. 22, no. 5, p. 1992, Mar. 2022. doi: 10.1016/j.ymeth.2019.06.014

[52] H. Zhao et al., “Weakly-Supervised Deep Learning for Whole Slide Breast Cancer Image Classification,” in *Proc. PUM Challenge @ MICCAI*, 2020. [Online]. Available: https://pumchallenge.org

[53] C. Zhao, "WSSS-Tissue," GitHub repository, 2023. [Online]. Available: https://github.com/ChuHan89/WSSS-Tissue

[54] M. Amgad et al., "Structured crowdsourcing enables convolutional segmentation of histology images," Bioinformatics, vol. 35, no. 18, pp. 3461–3467, 2019. [Online]. Available: https://github.com/CancerDataScience/CrowdsourcingDataset-Amgadetal2019

[55] M. Carles *et al*., "Development and evaluation of two open-source nnU-Net models for automatic segmentation of lung tumors on PET and CT images with and without respiratory motion compensation," *Eur. Radiol.*, vol. 34, no. 10, pp. 6701–6711, Apr. 2024, doi: 10.1007/s00330-024-10751-2.

[56] M. Ferrante *et al*., "Application of the nnU-Net for automatic segmentation of lung lesion on CT images, and implication on radiomic models," *arXiv preprint* arXiv:2209.12027, Sep. 2022. [Online]. Available: https://doi.org/10.48550/arXiv.2209.12027

[57] T. S. Mathai, B. Hou, and R. M. Summers, "Longitudinal Assessment of Lung Lesion Burden in CT," *arXiv preprint* arXiv:2504.06924, Apr. 2025. [Online]. Available: https://doi.org/10.48550/arXiv.2504.06924

[58] F. Hörst *et al.*, "CellViT++: Energy-efficient and adaptive cell segmentation and classification using foundation vision transformers," GitHub, 2024. [Online]. Available: https://github.com/TIO-IKIM/CellViT-plus-plus

[59] M. Antonelli et al., "The Medical Segmentation Decathlon," *Nature Communications*, vol. 13, art. no. 4128, Jul. 2022. doi: 10.1038/s41467-022-30695-9.

[60] A. Bermudez et al., “Automated breast tumor segmentation in DCE-MRI using nnU-Net and data augmentation,” *Computer Methods and Programs in Biomedicine*, vol. 233, 107418, 2023. doi: 10.1016/j.cmpb.2023.107418

[61] M. Alqaoud et al., "nnUNet-based Multi-modality Breast MRI Segmentation and Tissue-Delineating Phantom for Robotic Tumor Surgery Planning," in *Proc. Annu. Int. Conf. IEEE Eng. Med. Biol. Soc. (EMBC)*, Jul. 2022, pp. 3495–3501. doi: 10.1109/EMBC48229.2022.9871109

[62] F. Isensee et al., “nnU-Net for Brain Tumor Segmentation,” *ArXiv preprint*, Nov. 2020. Disponible en ArXiv:2011.00848

8. Anexo

8.1. Anexo 1: paquetes instalados en cada uno de los entornos

8.1.1. Entorno nnU-Net v2

El desarrollo del modelo basado en nnU-Net v2 se llevó a cabo en VSCode como entorno de desarrollo, en combinación con Python 3.11 y el entorno generado con Conda. Este entorno, creado específicamente para la ejecución y entrenamiento de nnU-Net, incluyó un conjunto de librerías esenciales tanto para el preprocesamiento de imágenes médicas como para el entrenamiento de redes neuronales profundas.

Entre los paquetes más relevantes destacan:

- nnunetv2 2.3.1: versión más reciente del framework nnU-Net, completamente reescrito y modularizado para mayor flexibilidad. [38]
- monai 1.4.0: biblioteca de PyTorch especializada en imágenes médicas, utilizada para evaluación del rendimiento y métricas adicionales. [39]
- batchgenerators 0.25.1: herramienta de generación de datos aumentados para entrenamiento robusto. [43]x
- simpleitk 2.4.1, dicom2nifti 2.5.1 y nibabel 5.3.2: fundamentales para la lectura y conversión de formatos de imagen médica (DICOM, NIfTI).[44][45][46]
- scikit-learn 1.6.1, scipy 1.15.2, pandas 2.2.3 y matplotlib 3.10.1: utilizadas para análisis de resultados, visualización de métricas y procesamiento estadístico. [42][47][48]
- torch 2.1.0, torchvision 0.16.0 y torchaudio 2.1.0 (cu121): motor de entrenamiento basado en GPU con soporte CUDA 12.1. [41]
- dynamic-network-architectures 0.3.1: módulo requerido por nnU-Net para definir automáticamente configuraciones de red según los datos. [23]
- Por último, numpy 1.26.4, pandas 2.2.3 y matplotlib 3.10.1: utilizados para procesamiento de datos, análisis estadístico y visualización de métricas. [40]

Además, se integraron utilidades como graphviz, pyvips, opencv-python-headless, y herramientas de control de versiones como yacs. El conjunto de librerías fue gestionado y mantenido a través de pip y conda-forge, garantizando compatibilidad y reproducibilidad del entorno. [38][39]

8.1.2. Entorno CellViT

Para el entorno de CellViT++, se configuró otro entorno Conda independiente optimizado para el procesamiento de imágenes histopatológicas a gran escala con modelos basados en Vision Transformers. Al igual que en el entorno empleado para nnU-Net, se utilizó Python como lenguaje principal (versión 3.10), y la mayoría de paquetes fueron instalados desde PyPI y conda-forge para asegurar compatibilidad con CUDA 12.x.

El entorno incorporó múltiples paquetes en común con nnU-Net, como numpy, pandas, matplotlib, scikit-learn, torch, torchvision, simpleitk, pydicom, opencv-python-headless y pyvips, esenciales tanto para la manipulación de imágenes como para la inferencia de modelos entrenados. [40][41][42]

Entre los paquetes específicos para el funcionamiento de CellViT, destacan einops, timm y albumentations, utilizados para la manipulación de tensores, arquitecturas Vision Transformer y aumentación de datos, respectivamente. Se incorporaron herramientas como huggingface-hub y torchmetrics para la evaluación, así como cucim, openslide-python y tiffslide para el manejo eficiente de imágenes histológicas en formato WSI. Además, ray permitió la paralelización de tareas, torchstain la normalización del color, y wandb el seguimiento opcional de experimentos.

8.1.3. Otros entornos

Fuera de los entornos principales, se crearon otros que fueron clave para el postprocesamiento, análisis espacial y visualización de regiones ricas en TILs tras la segmentación, que incluyen json para la lectura y manejo de anotaciones de instancias celulares exportadas por CellViT en formato GeoJSON; opencv-python (cv2): aplicado en tareas de procesamiento morfológico, como la dilatación binaria de máscaras para generar regiones continuas de TILs; scikit-learn con KDTree y DBSCAN (algoritmo de clustering espacial utilizado para detectar agrupaciones densas de células inmunes); y otras librerías para para operaciones de postprocesado sobre máscaras binarias como skimage.morphology. [40, 36, 47, 49]

8.2. Anexo 2: impactos económicos, éticos, sociales y medioambientales.

Este proyecto se ha desarrollado en un contexto clínico-académico, con el objetivo de aplicar técnicas avanzadas de inteligencia artificial para la segmentación automática de TILs en imágenes histopatológicas de cáncer de mama. Desde el inicio, se ha planteado no solo como un ejercicio técnico, sino como una herramienta con potencial para contribuir de forma real en el ámbito de la salud, en especial en tareas que actualmente suponen una gran carga de trabajo para el personal médico.

La motivación principal ha sido facilitar la identificación de regiones relevantes en muestras digitales, permitiendo una cuantificación más objetiva de los TILs y su uso posterior como complemento a métodos existentes como el test genético MammaPrint. Esto podría ser útil para mejorar la evaluación del riesgo de recurrencia y contribuir a una toma de decisiones más personalizada en oncología mamaria.

Durante el desarrollo del proyecto se han tenido en cuenta distintos aspectos relacionados con el impacto que este tipo de herramientas puede tener más allá del entorno puramente técnico. La posibilidad de integrar este tipo de soluciones en hospitales y centros de diagnóstico plantea implicaciones tanto positivas como retos en el plano social, ético, económico y medioambiental.

Este anexo recoge una reflexión detallada sobre estos posibles impactos, valorando el papel que pueden jugar modelos como el propuesto en la mejora del sistema sanitario, el uso eficiente de recursos, el respeto a los principios éticos y de privacidad, y la sostenibilidad tecnológica. El análisis pretende dar una visión completa y realista sobre cómo este tipo de desarrollos pueden trasladarse a la práctica clínica, qué beneficios pueden aportar y qué aspectos deben cuidarse especialmente para una implementación responsable.

8.2.1. Impactos económicos

El impacto económico de este proyecto se centra principalmente en la posibilidad de optimizar los recursos humanos y técnicos empleados en el análisis histopatológico del cáncer de mama. Automatizar esta tarea mediante herramientas de segmentación basadas en DL, como las desarrolladas en este trabajo, permite reducir significativamente el

tiempo de análisis por imagen, lo que se traduce en una mejora de la eficiencia operativa dentro del entorno hospitalario.

Además, el test genético MammaPrint representa un coste elevado en muchos sistemas sanitarios. Si este método de segmentación y cuantificación de TILs logra ofrecer un pronóstico fiable a partir de la información histológica, podría en determinados casos reducir o incluso evitar la necesidad de recurrir a estos test genómicos, lo que supondría un ahorro adicional y una mayor accesibilidad al diagnóstico personalizado.

También cabe destacar que el modelo propuesto ha sido desarrollado con herramientas de software libre y código abierto, como nnU-Net y CellViT++, lo cual elimina la necesidad de licencias comerciales y favorece la implementación en entornos clínicos con presupuestos limitados. El uso de plataformas como Visual Studio Code y librerías en Python contribuye además a mantener bajos los costes de desarrollo y mantenimiento del sistema, permitiendo su adaptación a distintos centros sanitarios sin grandes inversiones iniciales.

A medio y largo plazo, la incorporación de este tipo de sistemas podría contribuir a una reducción global de los costes del proceso diagnóstico, al mismo tiempo que permite liberar recursos humanos que podrían ser dedicados a tareas de mayor valor añadido. Todo ello posiciona a esta solución como una herramienta con potencial de impacto positivo desde el punto de vista económico, especialmente en un contexto donde se busca una mayor eficiencia del sistema sanitario sin comprometer la calidad asistencial.

8.2.2. Impactos éticos y sociales

El uso de inteligencia artificial en entornos clínicos plantea importantes cuestiones éticas, especialmente en lo referente a la transparencia de los modelos y al respeto por la privacidad del paciente. En este proyecto, todas las imágenes utilizadas han estado previamente anonimizadas y no han contenido datos personales en ningún momento. La herramienta está concebida para complementar el criterio médico, no para reemplazarlo, garantizando que las decisiones clínicas sigan estando en manos del personal sanitario.

Desde el punto de vista social, la automatización de la segmentación de TILs puede ayudar a mejorar la equidad en el acceso a un diagnóstico más uniforme y menos sujeto a la variabilidad entre especialistas. Esto resulta especialmente relevante en hospitales

con menos recursos humanos o alta carga asistencial, donde una herramienta como esta puede facilitar la priorización de casos y apoyar la calidad del diagnóstico. También contribuye al bienestar del personal médico, reduciendo tareas repetitivas y permitiendo que dediquen más tiempo a la atención directa de los pacientes.

8.2.3. Impactos medioambientales

Aunque este proyecto no implica directamente el uso de materiales físicos ni procesos industriales, sí conlleva un consumo energético asociado al entrenamiento y ejecución de modelos de aprendizaje profundo, especialmente al utilizar recursos de alto rendimiento como GPUs. El uso de una GPU NVIDIA A100 para entrenar redes como nnU-Net supone un gasto energético considerable, que contribuye indirectamente a la huella de carbono del sistema, especialmente si la fuente de energía no proviene de fuentes renovables.

Este tipo de impacto, aunque muchas veces invisible, es relevante cuando se considera la escalabilidad de estas soluciones a gran escala. Por ello, es importante apostar por prácticas más sostenibles en el desarrollo de inteligencia artificial, como optimizar los tiempos de entrenamiento, reducir la complejidad innecesaria de los modelos, o reutilizar pesos preentrenados siempre que sea posible. A medio plazo, la conciencia sobre el impacto ambiental del cómputo intensivo será clave para el diseño de soluciones más responsables dentro del ámbito sanitario y tecnológico.

8.2.4. Conclusiones

En conjunto, este proyecto demuestra que la aplicación de modelos de inteligencia artificial en el ámbito de la salud no solo puede aportar mejoras técnicas en precisión y eficiencia, sino que también conlleva una serie de implicaciones que deben considerarse desde una perspectiva amplia. La herramienta desarrollada ofrece beneficios potenciales en términos económicos y sociales, al facilitar un análisis más objetivo y accesible, pero también plantea retos éticos y medioambientales que requieren una reflexión crítica. La clave estará en aplicar estos sistemas de forma responsable, asegurando su transparencia, respetando los principios clínicos y avanzando hacia un uso más sostenible de los recursos computacionales.

8.3. Anexo 3: presupuesto económico

A continuación, se presenta el desglose del presupuesto estimado para el desarrollo del presente Trabajo Fin de Grado. Se han considerado tanto los costes directos, asociados al tiempo de trabajo invertido y al uso de recursos computacionales, como los costes indirectos derivados de la infraestructura empleada. El objetivo es reflejar de forma realista los recursos requeridos para implementar y evaluar los algoritmos de segmentación de TILs en imágenes histopatológicas de cáncer de mama mediante técnicas de aprendizaje profundo.

En este proyecto se ha utilizado un entorno de cómputo avanzado con GPU NVIDIA A100, necesario para el entrenamiento de redes como nnU-Net y para la ejecución del modelo CellViT++ sobre imágenes histológicas de gran resolución. Asimismo, se ha trabajado en un entorno Linux con software libre, destacando el uso de Python, nnU-Net, OpenCV, y otros paquetes asociados al procesamiento de imágenes médicas.

Se estiman 350 horas de trabajo técnico especializado en desarrollo, entrenamiento, evaluación y documentación, a un coste de 15 €/hora. Además, se ha realizado una estimación proporcional del uso del hardware y software, aplicando un criterio de amortización anual.

	Horas	Precio/Hora	Total
COSTE DE MANO DE OBRA (coste directo)	350	15 €	5.250,00 €

COSTE DE RECURSOS MATERIALES (coste directo)	Precio de compra	Uso en meses	Amortización (años)	Total
Ordenador personal (Software incluido)	1.500,00 €	10	5	250,00 €
GPU (uso servidor compartido A100)	6.000,00 €	7	5	700,00 €
Otro equipamiento	–	–	–	–

TOTAL RECURSOS MATERIALES	950,00 €

GASTOS GENERALES (costes indirectos) - 15% sobre CD	930,00 €
BENEFICIO INDUSTRIAL - 6% sobre CD+CI	427,80 €

MATERIAL FUNGIBLE

Impresión	100,00 €
Encuadernación	300,00 €

SUBTOTAL PRESUPUESTO	7.557,80 €
IVA APLICABLE (21%)	1.587,14 €
TOTAL PRESUPUESTO	9.144,94 €